

Partiel ML - DAC

1 heure 30 - Barème indicatif - Document : 1 feuille A4

✓ Exercice 1 (7 points) - The yes needs the no to win against the no

Pour chaque question, une seule réponse est correcte. Donner vos réponses, **sans justifier**, sous la forme 1-V si l'affirmation 1 est vraie, 1-F si elle est fautive (barème indicatif : +0.25/-0.125 par bonne/mauvaise réponse).

1. Le classifieur naïf bayésien est meilleur que le classifieur bayésien. **V**
2. Un choix de longueur de discrétisation trop petit dans la méthode des histogrammes peut conduire à du **F** *Ip 44*
sous apprentissage.
3. La densité d'une variable aléatoire est toujours inférieure à 1.
4. Le signe de l'entropie permet de déterminer l'aléa dans un ensemble de données.
5. La vraisemblance d'un jeu de données par rapport à un modèle idéal baisse lorsque le nombre de données augmente.
6. La régression logistique est adaptée pour prédire la note d'un film en fonction de ses caractéristiques.
7. Les classifieurs linéaires $w_1 = (1, -3, -2)$ et $w_2 = (5, -15, -10)$ sont équivalents.
8. La minimisation de $\sum_{i|y^i=1} \lambda_+ \mathbf{1}_{f(x^i) < 0} + \sum_{i|y^i=-1} \lambda_- \mathbf{1}_{f(x^i) \geq 0}$ selon le classifieur f avec 1 la fonction indicatrice et $\lambda_+ > \lambda_-$, favorise la classification des exemples comme positif plutôt que négatif.
9. Dans un noyau gaussien (pour l'estimation de densité), un petit σ - la variance - permet de baisser le sur-apprentissage.
10. Lorsque les données sont linéairement séparables, un perceptron est équivalent à un SVM linéaire.
11. Certaines frontières apprises avec un perceptron ne peuvent être apprises par un SVM avec un noyau polynomial.
12. Lors d'une descente de gradient en mode full batch sur tout l'ensemble des données, il n'est pas nécessaire de mélanger les exemples.
13. Pour un réseau de neurones à au moins deux couches cachées, ajouter des neurones dans une couche ne permet pas d'augmenter les performances.
14. Un coût $\max(0, 1 - f(x)y)$ est généralement meilleur que $\max(0, 0.1 - f(x)y)$ car il permet d'augmenter la marge des données avec les frontières de décision.
15. Pour apprendre un réseau de neurones, il suffit de connaître le gradient de la fonction de coût par rapport aux entrées de chaque couche et par rapport aux paramètres de chaque couche.
16. Les SVMs permettent de modéliser les probabilités a posteriori $P(y|x)$.
17. La rétro-propagation permet d'apprendre un optimum global d'un réseau de neurones
18. L'estimation de densité par noyaux nécessite une discrétisation de l'espace.
19. Une entropie strictement positive pour un ensemble de labels binaires indique la présence de plus de labels positifs que négatifs.
20. Lorsqu'on remarque qu'on sur-apprend en utilisant un K-NN, il vaut mieux augmenter K.
21. Pour un jeu de données linéairement séparable, on obtient la même frontière de décision si on entraîne un SVM sur toutes les données ou seulement sur les vecteurs supports trouvés lors de l'apprentissage sur toutes les données.
22. Le gradient est toujours orthogonal à la tangente des isocontours d'une fonction.
23. Quand les données sont non linéaires, un réseau de neurones est toujours plus adapté qu'un SVM.
24. Le classifieur naïf bayésien peut classifier correctement le problème XOR (échiquier à 4 cases)
25. Entre deux modèles il est préférable de retenir celui qui a la plus petite erreur en apprentissage.
26. La VC-dimension est utile pour déterminer le bruit dans les données
27. L'erreur en apprentissage diminue lorsque la VC-dim de la famille de classifieurs considérée augmente.
28. L'erreur d'apprentissage converge vers la vraie erreur lorsque le nombre de données en apprentissage tend vers l'infini si les données sont i.i.d.

Exercice 2 (5 points) – Ace of Bayes

Q 2.1 Un joueur de cartes sait que dans un jeu de carte normal, la hauteur des cartes peut varier autour d'une hauteur standard selon un x dont la distribution suit la loi suivante : $P(x) = \frac{\theta_1 e^{-x}}{(1+e^{-x})^{\theta_1+1}}$. Le paramètre θ_1 de cette loi lui est inconnu. Il dispose de N_1 cartes tirées de jeux normaux dont il a calculé l'ensemble des variations $D_1 = \{x^i\}_{i=1}^{N_1}$. Il souhaite estimer le paramètre θ_1 par maximum de vraisemblance.

Q 2.1.1 Donner l'expression de la log-vraisemblance des données en fonction de θ_1 et de N_1

Q 2.1.2 Montrer qu'une estimation de θ_1 est donnée par la formule $\theta_1 = \frac{N_1}{\sum_{i=1}^{N_1} \log(1+e^{-x_i})}$

Q 2.2 Il veut fabriquer un jeu de cartes "marqué" pour tricher. Pour cela, il souhaite faire varier de manière plus ample la hauteur des cartes selon un paramètre θ_2 . Une carte appartiendra donc soit au jeu normal, la classe C_1 , soit au jeu marqué, la classe C_2 . Au cours du jeu, il devra être en capacité de reconnaître si une carte est du paquet C_1 ou du paquet C_2 . On note λ_1 le coût de prédire la classe C_1 plutôt que la classe C_2 et λ_2 le contraire (un coût de zéro lorsqu'on ne se trompe pas). On notera dans la suite $p_1 = p(C_1)$ et $p_2 = 1 - p_1 = p(C_2)$.

Q 2.2.1 Donner l'expression des risques $R(C_1|x)$ et $R(C_2|x)$ de prédire C_1 et C_2 en un point x en fonction des λ_k , des $p(C_k)$, des $p(x|C_k)$ et de $p(x)$ pour $k = 1$ ou 2 .

Q 2.2.2 Quelle est la frontière de décision pour un classifieur bayésien optimal ?

Exercice 3 (4 points) – Réseau Clio

On considère le problème de classification en 2D suivant : la région située à l'intérieur du losange délimité par les segments $[(0,1), (1,0)], [(1,0), (0,-1)], [(0,-1), (-1,0)], [(-1,0), (0,1)]$ est positive, l'extérieur est négatif.

Q 3.1 Dessinez le problème de classification et donner un réseau de neurones capable de classer ce problème.

Q 3.2 Est-il possible de bien classer ce problème avec un classifieur naïf bayésien ? avec un arbre de décision ?

Q 3.3 Même question si on autorise une projection (pas trop complexe) des données d'entrée ?

Exercice 4 (6 points) – Total Reco

On considère un problème de recommandation où des utilisateurs sont indexés de 1 à M et des items de 1 à N . Certaines notes (entre 0 et 10) mises par les utilisateurs sur des items sont connues. L'objectif est de prédire les notes inconnues. Pour résoudre ce problème, on propose de construire un réseau de neurones qui à partir de l'index d'un utilisateur et de l'index d'un produit prédit la note attribuée par l'utilisateur au produit.

On considère une architecture très simple : le m -ème utilisateur est encodé par un vecteur one-hot (un vecteur de taille M contenant que des zéros sauf à la m -ème dimension qui contient un 1), le n -ème item est également encodé par un vecteur one-hot de dimension N . On notera e_m le vecteur one-hot correspondant à l'index m .

Le calcul de la note $\hat{y}$ à partir de l'utilisateur m et de l'item n est donné par l'architecture suivante :

- $z = (e_m.U; e_n.V)$, avec $U \in \mathbb{R}^{M \times L}$ et $V \in \mathbb{R}^{N \times L}$, le ; dénotant l'opération de concaténation de deux vecteurs (z est un vecteur de $\mathbb{R}^{2L}$).
- $x = \text{ReLU}(z.W^1)$ avec $W \in \mathbb{R}^{2L \times L}$, et $\text{ReLU}(t) = \max(0, t)$ la fonction d'activation
- $\hat{y} = g(x.W^2)$ avec $W^2 \in \mathbb{R}^{L \times 1}$ et g une fonction d'activation.

Q 4.1 À quoi correspond par rapport à la matrice U le vecteur $e_m.U$? Quelle est la signification de ce vecteur ?

Q 4.2 Quelle fonction d'activation proposez-vous pour g (la dernière couche) ? Quelle précaution prendre sur les notes du jeu d'apprentissage (en fonction de l'activation que vous avez choisie) ?

Q 4.3 On utilise un coût aux moindres carrés pour l'entraînement du réseau : $L(\hat{y}, y) = \frac{1}{2}(\hat{y} - y)^2$.

Q 4.3.1 Donnez l'expression de la dérivée $\frac{\partial L}{\partial w_i^2}$ pour w_i^2 un poids de W^2 , puis de $\frac{\partial L}{\partial x_i}$.

Q 4.3.2 Donnez l'expression de $\frac{\partial L}{\partial w_{i,j}^1}$ pour $w_{i,j}^1$ un poids de W^1 , puis de $\frac{\partial L}{\partial z_i}$.

Q 4.3.3 Donnez enfin l'expression de $\frac{\partial L}{\partial u_{m,j}}$ et de $\frac{\partial L}{\partial v_{n,j}}$.