

Partiel ML - DAC

1 heure 30 - Barème indicatif - Document : 1 feuille A4

Exercice 1 (7 points) – Ni oui ni non

Pour chaque question, une seule réponse est correcte. Donner vos réponses, **sans justifier**, sous la forme 1-V par exemple si l'affirmation 1 est vraie, 1-F si l'affirmation est fautive. Chaque bonne réponse apporte 0.25 points, chaque mauvaise retire 0.125 points à votre note (barème indicatif).

- ✓ 1. Le nombre de paramètres de l'estimation de densité à noyaux est plus grand pour un même problème que la méthode des histogrammes.
- ✓ 2. Pour le modèle $y = \alpha x_1 x_2^3 + \epsilon$ où ϵ est un bruit gaussien, α peut être appris avec une régression linéaire.
- ✓ 3. Pour le modèle $y = \log(\alpha x_1^{\alpha_1} e^{\alpha_2}) + \epsilon$ où ϵ est un bruit gaussien, les α peuvent être appris avec une régression linéaire.
- ✓ 4. Le bagging et le boosting opèrent tous les deux un ré-échantillonnage de l'ensemble d'apprentissage.
- ✓ 5. La densité d'une variable aléatoire peut être supérieure à 1.
- ✓ 6. La régression linéaire et la régression logistique sont deux bons choix lorsque les étiquettes sont continues.
- ✓ 7. L'estimation de densité est un préalable à toute approche de classification supervisée.
- ✓ 8. Le classifieur bayésien n'est pas toujours optimal.
- ✓ 9. Le classifieur naïf bayésien est approprié pour des données linéairement séparables.
- ✓ 10. Les SVMs permettent de modéliser les probabilités a posteriori $P(y|x)$.
- ✓ 11. Limiter la taille d'un arbre de décision permet de limiter le sur-apprentissage.
12. Pour un jeu de données linéairement séparable, un SVM linéaire donne de meilleurs résultats sur l'ensemble d'apprentissage qu'un perceptron.
- ✓ 13. Pour un jeu de données linéairement séparable, un SVM linéaire donne de meilleurs résultats sur l'ensemble de test qu'un perceptron.
- ✓ 14. La rétro-propagation permet d'apprendre un optimum global d'un réseau de neurones.
- ✓ 15. un K-NN est sensible à la mise à l'échelle des données.
- ✓ 16. Un arbre de décision est sensible à la mise à l'échelle des données.
- ✓ 17. Pour un jeu de données linéairement séparable, on obtient la même frontière de décision si on entraîne un SVM sur toutes les données ou seulement sur les vecteurs supports trouvés lors de l'apprentissage sur toutes les données.
- ✓ 18. Le gradient est toujours colinéaire à la tangente des isocontours de la fonction.
- ✓ 19. Quand les données sont non linéaires, un réseau de neurones est toujours plus adapté qu'un SVM.
- ✓ 20. Les coefficients de Lagrange sont toujours négatifs ou nuls.
- ✓ 21. Le signe de l'entropie permet de déterminer l'aléa dans un ensemble de données.
22. La vraisemblance d'un jeu de données par rapport à un modèle idéal augmente lorsque le nombre de données augmente.
- ✓ 23. La complexité du calcul d'un noyau polynomial est linéaire par rapport à d le degré du polynôme.
- ✓ 24. Un coût $\max(0, 1 - f(x)y)$ est généralement meilleur que $\max(0, 0.1 - f(x)y)$ car il permet d'augmenter la marge des données avec les frontières de décision.
25. Lorsqu'on remarque que l'on sur-apprend en utilisant un K-NN, il vaut mieux baisser K.
- ✓ 26. Entre deux modèles il est préférable de retenir celui qui a la plus petite erreur en apprentissage.
- ✓ 27. Selon l'algorithme de descente de gradient, il est toujours possible de trouver, si le gradient est non nul, un pas d'apprentissage permettant de faire décroître le coût à minimiser.
- ✓ 28. Il n'est pas possible de contrôler le sur-apprentissage lorsqu'on utilise une estimation de densité à noyaux.
- ✓ 29. L'estimation de densité à noyaux nécessite une discrétisation de l'espace.

Exercice 2 (5 points) - Erlang au chat

Soit $K = 3$ classes de chat C_k que l'on veut prédire à partir d'une caractéristique unidimensionnelle x , la taille de leur lange. Chaque classe est caractérisée par une probabilité a priori $P(C_k)$ et une densité conditionnelle $p(x|C_k)$ qui suit une loi d'Erlang : $p(x|C_k) = \theta_k^2 x e^{-x\theta_k} \Gamma(x)$ avec $\Gamma(x) = 1$ si $x > 0$, 0 sinon. On dispose de N données d'apprentissage $\{(x_i, y_i)\}_{i=0}^N$.

✓ Q 2.1 On souhaite estimer chaque θ_k par maximum de vraisemblance. Donner l'expression de la log-vraisemblance. En déduire l'estimation de θ_k .

Q 2.2 On utilise la règle de Bayes pour classifier, et un coût qui vaut 0 si la décision est bonne, α sinon.

✓ Q 2.2.1 Quelle est l'expression des risques conditionnels $R(C_k|x)$?

✓ Q 2.2.2 On suppose les classes C_k équiprobables, quelles sont les fonctions de décisions en fonction des θ_k ?

Exercice 3 (4 points) - Trivial Skipper

A partir d'une description des conditions de navigation dans $\mathbb{R}^d$ on souhaite prédire y le cap de navigation d'un voilier exprimé en radian. On propose d'utiliser la fonction : $\mathcal{L}(y, \hat{y}) = 1 - \cos(y - \hat{y})$ comme fonction de coût.

Q 3.1 Pourquoi ne pas utiliser un coût aux moindres carrés? Justifier que $\mathcal{L}$ est une fonction de coût adaptée.

Q 3.2 On propose d'utiliser un modèle linéaire f pour prédire $\hat{y}$ en fonction de $\mathbf{x} \in \mathbb{R}^d$.

Q 3.2.1 Donner les paramètres de f et son expression.

Q 3.2.2 Donner un algorithme (complet) pour apprendre les paramètres de f à partir d'un jeu de données $\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$. (Rappel : $\cos'(x) = -\sin(x)$)

Q 3.3 On souhaite modifier la fonction de coût afin de contrôler le sur-apprentissage. Que préconisez vous? Quel(s) changement(s) apporter à l'algorithme d'apprentissage?

Exercice 4 (6 points) - Regression Lagrangienne

Soit un problème de régression avec les données $\{\mathbf{x}^i, y^i\}_{i=1 \dots N}$, $\mathbf{x}^i \in \mathbb{R}^d$ et $y^i \in \mathbb{R}$. On cherche une solution linéaire : $f_{\mathbf{w}}(\mathbf{x}) = \langle \mathbf{w}, \mathbf{x} \rangle$. Le problème d'optimisation sous contrainte associé est :

$$\min_{\mathbf{w}, \xi, \lambda} \lambda \|\mathbf{w}\|^2 + \sum_{i=1}^N \xi_i^2, \text{ sous contraintes } y^i - \langle \mathbf{w}, \mathbf{x}^i \rangle = \xi_i \quad \forall i \in \{1, \dots, N\}$$

✓ Q 4.1 Quel rapport entre cette formulation et la formulation du problème de régression linéaire aux moindres carrés? Quel est le rôle de λ ?

✓ Q 4.2 Donner le Lagrangien du problème, on appellera α_i les constantes introduites pour les contraintes.

✓ Q 4.3 Donner l'expression de $\mathbf{w}$ et des ξ_i en fonction des α_i et des $\mathbf{x}^i$ à l'aide des conditions d'optimalité.

✓ Q 4.4 Donner la formulation duale du problème où n'apparaissent plus les ξ_i et $\mathbf{w}$.

✓ Q 4.5 En considérant K la matrice de terme général $K_{i,j} = \langle \mathbf{x}^i, \mathbf{x}^j \rangle$, α le vecteur des α_i et $\mathbf{y}$ le vecteur des N labels, donner une formulation matricielle de la forme duale.

✓ Q 4.6 En considérant cette dernière expression, trouver la solution du dual pour α .

Exercice 5 (3 points) - Time's Up

Proposer un réseau de neurones permettant de classifier l'intérieur du sablier correctement.

