


Apprentissage non supervisé

Réduction de dimension



Cours 4
ML
Master MIND

Nicolas Baskiotis

`nicolas.baskiotis@sorbonne-universite.fr`

équipe MLIA, Institut des Systèmes Intelligents et de Robotique (ISIR)
Sorbonne Université

S2 (2025-2026)

Plan

1 Introduction

2 Clustering

- K -Means
- Clustering Agglomératif
- Clustering par densité
- Spectral clustering
- Evaluation d'un clustering

3 Réduction de dimension

- Motivations
- Principal Component Analysis
- Préservation des distances
- Apprentissage de dictionnaire

Que faire sans label de disponible ...

Pourquoi et quand ?


- pas le temps ni l'argent
- pas de spécialiste pour étiquetter
- impossible à étiquetter
- évolution dynamique des structures
- trop de catégories sans beaucoup de sens
- l'important est la structuration des données, les motifs
- on ne sait pas ce qu'on cherche
- ...

Principe

- Regrouper tout ce qui se ressemble,
- Eloigner tout ce qui est franchement différent.
- Un *cluster* : un regroupement de donnée.

Simple, mais ...

Données




Clustering

Principe

- Regrouper tout ce qui se ressemble,
- Eloigner tout ce qui est franchement différent.
- Un *cluster* : un regroupement de donnée.

Simple, mais ...

Données



Clustering



Principe

- Regrouper tout ce qui se ressemble,
- Eloigner tout ce qui est franchement différent.
- Un *cluster* : un regroupement de donnée.

Simple, mais ...

Données



Clustering



Principe

- Regrouper tout ce qui se ressemble,
- Eloigner tout ce qui est franchement différent.
- Un *cluster* : un regroupement de donnée.

Simple, mais ...

Données



Clustering



Principe

- Regrouper tout ce qui se ressemble,
- Eloigner tout ce qui est franchement différent.
- Un *cluster* : un regroupement de donnée.

Simple, mais ...

Données




Clustering








- L'apprentissage non supervisé : très subjectif !
- Pas de but global bien défini, l'objectif est induit par la formulation du problème.

Example




Exemple

Quel est le bon clustering ?



Exemple

Quel est le bon clustering ?



aucun ! (distribution uniforme)

Apprentissage non supervisé

- Ensemble très varié de techniques qui visent à trouver des sous-ensembles cohérents des données
 - Tout ce qui ressemble s'assemble $\Rightarrow$ définir une *similarité* entre exemples
 - Deux principales approches :
 - ▶ par partitionnement
 - ▶ par modélisation
 - Un clustering peut être:
 - ▶ *hard* (un exemple n'appartient qu'à un groupe)
 - ▶ *soft* (probabilité d'appartenance)
- $\Rightarrow$ Domaine-spécifique, pas de règle générale, tout dépend de la tâche !

Formalisation et évaluation

Objectif

- Soit $D = x^1, \dots, x^N \in \mathcal{X}$ un jeu de données
- Construire une projection $f : \mathbb{R}^d \rightarrow \{1, \dots, K\}$ telle que à chaque x^i un cluster j est associé
- Le choix de K est difficile !

Comment évaluer ?

- Similarité: mesure quantitative de la similarité dans un cluster (distance intra-cluster) comparée aux autres clusters (distance extra-cluster)
- Variance: stabilité des résultats (sous-échantillonnage, bruit artificiel ...)
- Connaissances expertes: expertise qualitative sur la signification des clusters

Plan

1 Introduction

2 Clustering

- K -Means
- Clustering Agglomératif
- Clustering par densité
- Spectral clustering
- Evaluation d'un clustering

3 Réduction de dimension

- Motivations
- Principal Component Analysis
- Préservation des distances
- Apprentissage de dictionnaire


Clustering par partitionnement : k -means

Objectif

- Clustering des données pour minimiser la distance intra-cluster
- Etant donnée $d : X \times X \rightarrow \mathbb{R}$ une distance
- Minimiser :

$$\operatorname{argmin}_{\pi=(D_1, \dots, D_K)} \sum_{i=1}^K \sum_{x_j \in D_i} d(x_j, \mu_i)$$

- avec μ_i le centroïde du cluster i , i.e. $\mu_i = \frac{1}{|D_i|} \sum_{x_j \in D_i} x_j$



Clustering par partitionnement : k -means

Objectif

- Clustering des données pour minimiser la distance intra-cluster
- Etant donnée $d : X \times X \rightarrow \mathbb{R}$ une distance
- Minimiser :

$$\operatorname{argmin}_{\pi=(D_1, \dots, D_K)} \sum_{i=1}^K \sum_{x_j \in D_i} d(x_j, \mu_i)$$

- avec μ_i le centroïde du cluster i , i.e. $\mu_i = \frac{1}{|D_i|} \sum_{x_j \in D_i} x_j$

Remarques

- NP -difficile (très difficile)
- Chaque centroïde est la quantization d'un cluster : *prototype*
- Très similaire à la notion de compression

Algorithme des K-means

Algorithme en deux étapes

Initialiser avec un clustering aléatoire

- 1 Mise à jour des centroïdes: $\mu_i = \frac{1}{|D_i|} \sum_{x_j \in D_i} x_j$
- 2 Assigner à chaque exemple x_j le cluster le plus proche ($\operatorname{argmin}_{i \in \{1, \dots, K\}} d(x_j, \mu_i)$)

Répéter le deux étapes jusqu'à stabilité

Initialisation





- Résultats très sensibles à l'initialisation
- Converge souvent vers un minimum local $\Rightarrow$ multiples tentatives et prendre la meilleure

Détails





- Initialisation aléatoire des k centres : $\mu^0 = (\mu_1^0, \dots, \mu_K^0)$
- Affectation des points x_j : classe $C^t(x_j) = \operatorname{argmin}_i \|\mu_i^t - x_j\|^2$
- Estimation des centres : $\mu_i^{t+1} = \sum_{j:C^t(x_j)=i} \mu - x_j \|^2$
- On optimise $C^t = (C^t(x_j))$ et $\mu = (\mu_i)$
- Fonction de coût : $F(\mu, C) = \sum_j \|\mu_{C(x_j)} - x_j\|^2 = \sum_{i=1}^K \sum_{j:C(x_j)=i} \|\mu_i - x_j\|^2$
- Première étape : on fixe μ , on optimise $C \Rightarrow$ Calcul de l'espérance
- Seconde étape : on fixe C , on optimise $\mu \Rightarrow$ Calcul du maximum de vraisemblance

Algorithme dit *Expectation/Maximization*, (EM)

Examples



Examples




Utilisation pour la segmentation et la compression

Par moyennage des couleurs : nombre de couleurs = nombre de clusters




Autre approche, 2 couleurs par cellule :



Inconvénients des K-moyennes

Clusters convexes

- En fait, partitionnement Voronoi
- Clusters définis uniquement par leur centroïde
- Pas d'hierarchie: on ne peut fusionner/diviser des clusters



Clustering hiérarchique

Inconvénients des K-moyennes

Pas d'hiérarchie dans les clusters (i.e. décroître le K ne fusionne pas les clusters)

Comment prendre en compte une hiérarchie ?

- Considérer des méthodes très simples en prenant en compte des mesures de similarité entre clusters
- Soit avec des approches agglomératives en fusionnant les clusters de manière bottom-up
- ou au contraire en divisant de manière top-down les clusters

Approches agglomératives

Algorithme glouton



- Commencer avec N clusters chacun contenant un exemple
 - Fusionner les clusters les plus similaires deux à deux
 - Jusqu'à n'avoir plus qu'un cluster
- ⇒ Construction d'un dendrogramme: un arbre de partitionnement

Distance entre clusters ?

Plusieurs choix, mais souvent pas une vraie distance (un *linkage*) :

- $d(c_1, c_2) = \min d(x, x'), x \in c_1, x' \in c_2$ (*single linkage*)
- $d(c_1, c_2) = \max d(x, x'), x \in c_1, x' \in c_2$ (*complete linkage*)
- $d(c_1, c_2) = \mathbb{E}(d(x, x')), x \in c_1, x' \in c_2$

Examples



Clustering par densité

Hypothèse: régions denses sont séparées par des régions de faible densité

Algorithme générique:



- Estimer la densité d'une région
 - Trouver les points appartenant à cette région dense
 - Rassembler ces points en un cluster
-
- Estimation de densité: estimation par noyaux
 - Regroupement: lier les points de haute densité et les considérer comme un cluster.
 - DBSCAN est l'algorithme le plus utilisé: efficace et capable de déterminer automatiquement le nombre de clusters

DBSCAN Density-based Spatial Clustering of Applications with Noise

Pour chaque point, considérer l'ensemble des points atteignables par densité autour de ce point

- Calculer le voisinage à ϵ de ce point
- Si le voisinage contient plus de m points, calculer le voisinage de chacun de ces points
- jusqu'à ce que le cluster se stabilise.

Si le point n'a pas assez de voisins, il est considéré comme du bruit.




Pour/contre de DBSCAN


- Pas besoin de pré-définir un nombre de clusters
 - Peut trouver des clusters de forme arbitraire
 - Evite l'effet single-link (clusters connectés par une connection fine)
 - Introduit de manière naturelle la notion de outliers/bruits
- Mais
- Difficulté du choix des hyper-paramètres (m et ϵ)
 - Peut pas trouver des clusters avec des densités différentes
 - Curse of dimensionality ...

Spectral clustering : Problématique

K-means



Spectral clustering




Limites des approches vues

- K-means (et en général clustering de métrique) ne trouvent que des clusters sphériques
- Comment encoder une structuration des données ? des relations de voisinages ?
- Une solution parmi d'autres : spectral clustering $\Rightarrow$ projeter les données sur un graphe de relation

Graphe de données

Notations graphe

- Données : les nœuds $V = \{x_i\}$ du graphe
- Les liens/arêtes pondérés : $E = \{w_{ij} = s(x_i, x_j)\}$ similarité entre données
- Restriction : graphe connexe




Création du graphe

- Difficile de travailler sur un graphe entièrement connecté :
 - ▶ seuil sur la mesure de similarité
 - ▶ k -nn avec k fixé
- ou utilisation de noyaux pour pondérer les arêtes : $w_{ij} = e^{-\|x_i - x_j\|^2 / \sigma^2}$

Objectif

- Toujours le même :
 - ▶ données d'un même cluster très similaires
 - ▶ données de différent cluster dissimilaires
- En termes de graphe :
 - ▶ Notion de coupe : $cut(C_1, C_2) = \sum_{i \in C_1, j \in C_2} w_{ij}$, $C_1 \cap C_2 = \emptyset$
 - ▶ Coupe normalisé : $NormCut(C_1, C_2) = \frac{Cut(C_1, C_2)}{Vol(C_1)} + \frac{Cut(C_1, C_2)}{Vol(C_2)}$,
 $Vol(C) = \sum_{i,j \in C} w_{ij}$
- Problème NP-difficile...




$$Cut(BCDE, A) = 0.17$$

$$NormCut(BCDE, A) = 1.067, NormCut(ABC, DE) = 1.038$$

Representation matricielle

- Matrice de similarité/d'adjacence: $N \times N$,
- $W : \{w_{i,j}\}$
- Matrice symétrique
- D matrice des degrés : $d_{i,i} = \sum_j w_{ij}$ pour normaliser la matrice d'adjacence



Représentation matricielle

- Matrice considéré : matrice laplacienne : $L = D - W$
- Propriétés :
 - ▶ Valeurs propres positives
 - ▶ Vecteurs propres orthogonaux
 - ▶ Ce sont des indicateurs de la connectivité du graphe
- Pour deux partitions C_1, C_2 :
 - ▶ soit f un vecteur dans $\{-1, 1\}$ de taille n , tel que $f_i = 1$ si $i \in C_1$, -1 si $i \in C_2$.
 - ▶ On montre que $f'Lf = \frac{1}{2} \sum_{i,j} w_{i,j}(f_i - f_j)^2$, c'est-à-dire le coût de la coupe selon cette partition :

$$\begin{aligned} f'Lf &= f'(D - W)f = f'Df - f'Wf = \sum_i d_i f_i^2 - \sum_{i,j} f_i f_j w_{ij} \\ &= \frac{1}{2} \left(\sum_i \left(\sum_j w_{ij} \right) f_i^2 - 2 \sum_{i,j} f_i f_j w_{ij} + \sum_j \left(\sum_i w_{ij} \right) f_j^2 \right) = \frac{1}{2} \sum_{i,j} w_{i,j} (f_i - f_j)^2 \end{aligned}$$

Optimisation de la coupe normalisée

Soit A un sous-ensemble de nœud du graphe

- Soit $f_i = \sqrt{\frac{|\bar{A}|}{|A|}}$ si le nœud i est dans A , $-\sqrt{\frac{|A|}{|\bar{A}|}}$ sinon.
- $f'Lf = \sum_{i,j} w_{i,j}(f_i - f_j)^2 =$
$$\sum_{i \in A, j \in \bar{A}} w_{i,j} \left(\sqrt{\frac{|\bar{A}|}{|A|}} + \sqrt{\frac{|A|}{|\bar{A}|}} \right)^2 + \sum_{i \in \bar{A}, j \in A} w_{i,j} \left(-\sqrt{\frac{|\bar{A}|}{|A|}} - \sqrt{\frac{|A|}{|\bar{A}|}} \right)^2$$
- Or $cut(A, \bar{A}) = \sum_{i \in A, j \in \bar{A}} w_{i,j}$, donc $f'Lf = cut(A, \bar{A}) \left(\frac{|\bar{A}|}{|A|} + \frac{|A|}{|\bar{A}|} + 2 \right)$

$$\Rightarrow f'Lf = 2|V|Ratio_{cut}(A, \bar{A})$$

- De plus, $f'.1 = \sum_i f_i = \sum_{i \in A} \sqrt{\frac{|\bar{A}|}{|A|}} - \sum_{i \in \bar{A}} \sqrt{\frac{|A|}{|\bar{A}|}} = 0$
- et $\|f\|^2 = |V|$

Le problème d'optimisation relaxé est donc :


$$\min_f f'Lf, \text{ tel que } f'.1 = 0 \text{ et } \|f\|^2 = |V|$$

Comment choisir le nombre de clusters ?

Méthode Elbow

- Faire varier le nombre de clusters
- Etudier le ratio entre la moyenne des distances intra-cluster et la variance totale du jeu de données
- Equivalent à étudier le pourcentage de la variance expliquée par le clustering comme une fonction du nombre de clusters





La courbe a généralement deux régimes: une avec une chute rapide du ratio et l'autre plus stable.




Comment choisir le nombre de clusters ?

Coefficient silhouette: dénote une sorte d'homogénéité des clusters

- Silhouette d'un point i is $\frac{b(i)-a(i)}{\max(a(i), b(i))}$
- avec $a(i)$ la moyenne de la distance intra-cluster d'un point
- et $b(i)$ la moyenne de la distance aux points du cluster le plus proche.
- Une grande valeur de silhouette dans un cluster dénote une haute homogénéité.



Conclusion : Différentes approches pour des problèmes variés ...



sklearn - Overview of clustering methods

Conclusions générales

Questions à se poser

- Qu'est-ce qu'un cluster ?
- Comment définir la similarité ?
- Quels features, quelle normalisation ?
- Combien de clusters ?
- Quelle méthode de clustering ?
- Les résultats ont-ils un sens ? clusters valides ?

Plan

1 Introduction

2 Clustering

- K -Means
- Clustering Agglomératif
- Clustering par densité
- Spectral clustering
- Evaluation d'un clustering


3 Réduction de dimension

- Motivations
- Principal Component Analysis
- Préservation des distances
- Apprentissage de dictionnaire

Réduction de dimension: Pourquoi ?

Analyse de données/Visualisation


- Comment sont distribuées les données ?
- Des dimensions sont-elles importantes ?
- Les classes sont-elles bien séparées ?




Réduction de dimension: Pourquoi ?

Interprétabilité

- Moins de dimension $\Rightarrow$ meilleure explicabilité
- Des dimensions redondantes et non pertinentes dégradent les performances des algorithmes



Real risk = 0.92 ± 0.05




Real risk = 0.92 ± 0.06

Réduction de dimension: Pourquoi ?

Souvent les données résident dans un espace de petite dimension

- Pas de perte d'information en réduisant le nombre de dimensions
- Curse of Dimensionality :

$d^{-1/2}(\max\|X_i - X_j\| - \min\|X_i - X_j\|) \rightarrow 0, \frac{\max\|X_i - X_j\|}{\min\|X_i - X_j\|} \rightarrow 1$ quand $d \rightarrow \infty$
tous les points sont quasiment équidistants ...



Réduction de dimension: Pourquoi ?



Deux approches principales

- Sélection de dimensions : trouver un sous-ensemble des dimensions d'origine
 - ▶ L'algorithme lui-même se restreint à un certain nombre de dimensions (pénalisation, expressivité)
 - ▶ Filtrage : des mesures d'évaluations pour juger l'intérêt de chaque dimension
 - ▶ Posthoc : éliminer certaines dimensions et observer la variance des performances
- Construire de nouvelles dimensions !
 - ▶ en considérant une erreur de reconstruction
 - ▶ ou en conservant les distances entre exemples

Principal Component Analysis

Principe:


- Trouver une nouvelle base avec très peu de dimensions
- Chaque dimension est une combinaison linéaire des dimensions d'origine
- Chaque nouvelle dimension doit décrire le plus d'information possible $\Rightarrow$ Maximisation de la variance



Principal Component Analysis

Pour plusieurs dimensions


- Choix optimal donné par la valeur propre maximale de la matrice de covariance $(X - \mu)(X - \mu')$
- Inertie projetée donnée par la somme des valeurs propres.
- Souvent chute rapide des valeurs propres.



Principal Component Analysis : Interprétation

Cercle de corrélation


- les variables corrélées positivement sont groupées.
- les variables corrélées négativement sont positionnées à l'opposé
- les variables loin de l'origine sont bien représentées



Principal Component Analysis : Interprétation

Graphique des individus



- Individus proches ont tendance à être similaire
- Mais il faut regarder les autres dimensions !
- Ceux proches de l'origine ne sont pas bien représentés par les axes



Multi-dimensional Scaling (MDS)

Objectifs:

- Trouver une projection des données de manière à préserver les distances deux à deux des points
- Ne calcule pas explicitement des nouvelles dimensions
- Utilisé essentiellement pour de la visualisation
- Ne nécessite pas explicitement la description des exemples, uniquement les distances deux à deux.



Multi-dimensional Scaling (MDS)

Principe:


- Matrice de Gram : $G = (X - m)(X - m)^T$ avec $m = \frac{1}{N} \sum_{i=1}^N \mathbf{x}_i$
- Nouvelles coordonnées : $x' = U^T(x - m)$ avec U orthonormale
- Objectif : Minimiser le produit scalaire entre les vecteurs
$$\sum_{i=1}^N \sum_{j=1}^N (\langle x_i - m, x_j - m \rangle - \langle x'_i, x'_j \rangle)^2$$
- Equivalent à minimiser :
$$\sum_{i=1}^N \sum_{j=1}^N (\langle x_i - m, x_j - m \rangle - (x_i - m)^T U U^T (x_j - m))^2 \text{ wrt } U^T(x_i - m)$$
- Solution donnée par les vecteurs propres de G
- Très similaire à la PCA mais sur XX^T plutôt que $X^T X$

Inconvénients:

- Prend en compte toutes les dimensions (bruit, corrélation, ...)
- Applicable que si $N \ll d$ et si d est petit ...

Isomap


- La distance euclidienne n'est pas toujours la *bonne* distance
- Essaye de préserver la distance géodésique des données
- En suivant un chemin à travers les données




Isomap

Principe:


- Calcule le graphe de voisinage (avec un K-NN par exemple)
- Calcule la distance entre les points deux à deux dans ce graphe (chemin pondéré le plus court entre les points)
- Un MDS est utilisé sur le résultat



PCA projection



IsoMap projection



Objectif

- Trouver une projection qui conserve le voisinage de chaque point
- Pas de transformation explicite, seulement les nouvelles coordonnées
- Pas d'hypothèse sur l'espace d'origine, seul la distance deux à deux est utilisée


Principe

- Soit $P_{j|i} = \frac{e^{-\|x_i - x_j\|^2 / 2\sigma_i^2}}{\sum_k e^{-\|x_i - x_k\|^2 / 2\sigma_i^2}}$, la probabilité que x_i choisisse x_j comme voisin
- Trouver les nouvelles coordonnées x'_i telles que $Q_{j|i}$ la distribution de probabilité dans le nouvel espace est proche de $P_{j|i}$.
- Utilise une distance de Kullback-Leibler afin de faire correspondre les distributions en utilisant une descente de gradient


t-SNE

Interpretation

- le voisinage local est conservé : les points proches sont également proches dans l'espace d'origine
 - Mais les distances ne sont pas préservées !
- ⇒ en dehors d'une petite région autour d'un point, les autres distances n'ont pas de sens !
- Attention : en fonction de l'hyperparamètre, il est très facile de construire des petits clusters isolés, mais souvent sans aucune signification !



Apprentissage de dictionnaire




- Une image : constituée d'un petit ensemble de primitives.
- Problème de la PCA : base orthogonale ! pas de redondance
- Peut-on apprendre un dictionnaire de primitives pour représenter un jeu de données ?

Compress sensing

- Objectif : trouver D tel que $x \approx Dx'$
- Contrainte de sparsité : $\|x'\|_0$ très faible, peu d'*atomes* sont nécessaires à reconstruire x
 - ▶ simplicité : quelques atomes suffisent à expliquer x
 - ▶ signification : la représentation explique x
 - ▶ parcimonie : x est décrit que parce qui le représente
- Problème d'optimisation : $\operatorname{argmin}_D \|Dx' - x\| + \lambda \|x'\|_0$ (différentes normes, différentes variantes)
- Approche dérivée de la physique (analyse de wavelet, fourier, ...)

Applications



Débruitage

[Mairal et al 2009]

Applications




Inpainting

[Mairal, Elad, Sapiro 2008]

Factorisation matricielle non négative

- Décomposition sur un dictionnaire additif uniquement
- $x \approx Dx'$, avec $x' > 0$
- Intérêt : plus interprétable, plus réaliste sur un ensemble de problèmes




Multiples applications : séparation de sources, en topic discovery, ...

Auto-encoders

Principe

- Apprendre un réseau de neurones qui reconstruit au mieux l'entrée
- Encodage sur une couche cachée $\Rightarrow$ réduction de dimension



Applications

- Visualisation
- Débruitage
- Réduction de dimension, espace latent de représentation