

Inférence Variationnelle

Application à l'inférence bayésienne

Clément Rambour

Sorbonne Université
ISIR - équipe MLIA

Apprentissage classique en apprentissage automatique

- Objectif : apprendre des paramètres w à partir de données D

- Formulation standard :

$$\hat{w} = \arg \min_w \mathcal{L}(w)$$

- Exemples :

- Régression linéaire
- Régression logistique
- SVM

- Résultat : **un unique estimateur $\hat{w}$**

Limites de l'approche classique

- Les données sont :
 - limitées
 - bruitées
- Plusieurs paramètres peuvent expliquer les données
- Problème :
 - Pas de mesure d'incertitude sur w
 - Pas de confiance sur les prédictions
- Question clé :

À quel point doit-on faire confiance au modèle appris ?

Inférence bayésienne

- Plutôt que d'estimer un point, on estime une **distribution**

$$p(w|D)$$

- Interprétation :
 - valeurs probables de w
 - incertitude sur les paramètres

- Prédiction bayésienne :

$$p(y|x, D) = \int p(y|x, w) p(w|D) dw$$

- $\Rightarrow$ moyenne sur tous les modèles plausibles

Pourquoi utiliser une approche bayésienne ?

- **Quantification de l'incertitude**
 - prédictions plus fiables
- **Robustesse**
 - évite le surapprentissage
- **Décision sous incertitude**
 - savoir quand le modèle ne sait pas
- Idée clé :

Apprendre une distribution de modèles plutôt qu'un seul modèle

Le défi principal : l'inférence

- Loi de Bayes :

$$p(w|D) = \frac{p(D|w)p(w)}{p(D)}$$

- Terme problématique :

$$p(D) = \int p(D|w)p(w) dw$$

- Intégrale souvent :
 - non calculable
 - de grande dimension

- Objectif du cours :




Comment approximer efficacement $p(w|D)$?

- $\Rightarrow$ MAP, Laplace, Inférence variationnelle

Robustesse en apprentissage profond

Apprentissage profond : gain majeur en performance moyenne, e.g. en précision pour la classification



- Besoin de **garanties de performance dans les applications critiques : robustesse**
 - Santé, conduite autonome, nucléaire, défense, etc.



Robustesse en apprentissage automatique

• Références :

- Pattern Recognition and Machine Learning [Bishop, 2006]
- Machine Learning : A Probabilistic Perspective [Murphy, 2012]



- 1 Inférence bayésienne
- 2 Exemple : Régression linéaire bayésienne
- 3 Au-delà de la régression linéaire
- 4 Inférence variationnelle


Quantification de l'incertitude

Intuition

Comment évaluer la stabilité d'un modèle donné par rapport à un jeu d'entraînement ?

Naïvement :

- entraîner plusieurs modèles avec des graines / initialisations différentes
 - moyenner les prédictions dans l'espace d'entrée pour obtenir une distribution empirique des sorties du modèle
- ↪ nécessite plusieurs entraînements




Modèles bayésiens

Intuition

Comment évaluer la stabilité d'un modèle donné par rapport à un jeu d'entraînement ?

Approche bayésienne :


- estimer la distribution du modèle $\Leftrightarrow$ la distribution de ses paramètres
- estimer la distribution prédictive $\Leftrightarrow$ la distribution de la prédiction dans l'espace d'entrée



Modèles bayésiens

- Jeu de données $\mathcal{D} = (\mathbf{X}, \mathbf{Y})$ avec entrées $\mathbf{X} = \{\mathbf{x}_i\}_{i=1}^N$ et sorties $\mathbf{Y} = \{\mathbf{y}_i\}_{i=1}^N$
 - $\mathbf{x}_i \in \mathbb{R}^d$, $\mathbf{y}_i^* \in \mathbb{R}^K$ (classification ou régression)
 - Modèle de paramètres $\mathbf{w}$: $\hat{\mathbf{y}}_i = f_{\mathbf{w}}(\mathbf{x}_i)$
- Règle de Bayes : $p(\mathbf{Y}, \mathbf{w} / \mathbf{X}) = p(\mathbf{Y} / \mathbf{X}, \mathbf{w})p(\mathbf{w}) = p(\mathbf{w} / \mathbf{X}, \mathbf{Y})p(\mathbf{Y} / \mathbf{X})$

$$\Rightarrow \boxed{p(\mathbf{w} / \mathbf{X}, \mathbf{Y}) = \frac{p(\mathbf{Y} / \mathbf{X}, \mathbf{w})p(\mathbf{w})}{p(\mathbf{Y} / \mathbf{X})} \propto p(\mathbf{Y} / \mathbf{X}, \mathbf{w})p(\mathbf{w})}$$



A photograph of a chalkboard with the formula for Bayes' theorem written in blue chalk. The formula is $P(A|B) = \frac{P(B|A)P(A)}{P(B)}$. The text is written in a casual, handwritten style.

Modèles bayésiens

Apprentissage déterministe vs. bayésien

- **Les modèles déterministes** apprennent les paramètres $\mathbf{w}$ du modèle sur le jeu d'entraînement $\mathcal{D}$ en minimisant la perte espérée $\mathcal{L}$:

$$\mathbf{w} = \underbrace{\operatorname{argmin}_{\mathbf{w}}}_{\text{trouver les meilleurs paramètres } \underline{\text{fixes}}} \underbrace{\mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim p(\mathcal{D})}}_{\text{données échantillonnées depuis } \mathcal{D}} \mathcal{L}(f_{\mathbf{w}}(\mathbf{x}), \mathbf{y})$$

Modèles bayésiens

Apprentissage déterministe vs. bayésien

- **Les modèles déterministes** apprennent les paramètres $\mathbf{w}$ du modèle sur le jeu d'entraînement $\mathcal{D}$ en minimisant la perte espérée $\mathcal{L}$:

$$\mathbf{w} = \underbrace{\operatorname{argmin}_{\mathbf{w}}}_{\text{trouver les meilleurs paramètres } \underline{\text{fixes}}} \underbrace{\mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim p(\mathcal{D})}}_{\text{données échantillonnées depuis } \mathcal{D}} \underbrace{-\log p(\mathbf{y}|\mathbf{x}, \mathbf{w})}_{\text{Loss = negative log-likelihood}}$$

Modèles bayésiens

Apprentissage déterministe vs. bayésien

- **Les modèles déterministes** apprennent les paramètres $\mathbf{w}$ du modèle sur le jeu d'entraînement $\mathcal{D}$ en minimisant la perte espérée $\mathcal{L}$:

$$\mathbf{w} = \underbrace{\operatorname{argmin}_{\mathbf{w}}}_{\text{trouver les meilleurs paramètres fixes}} \underbrace{\mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim p(\mathcal{D})}}_{\text{données échantillonnées depuis } \mathcal{D}} \underbrace{-\log p(\mathbf{y}|\mathbf{x}, \mathbf{w})}_{\substack{\text{Loss=} \\ \text{negative log-likelihood}}}$$

- **Les modèles bayésiens** apprennent la distribution de $\mathbf{w}$ conditionnellement au jeu d'entraînement $p(\mathbf{w}|\mathcal{D})$. Le meilleur modèle $\mathbf{w}^*$ est appelé maximum a posteriori (MAP) :

$$\mathbf{w}^* = \underbrace{\operatorname{argmin}_{\mathbf{w}}}_{\substack{\text{trouver les meilleurs paramètres} \\ \text{à partir de leur } \underline{\text{distribution}}}} -\log \underbrace{p(\mathbf{w}|\mathcal{D})}_{\substack{\text{distribution conditionnelle} \\ \text{des paramètres}}}$$

Modèles bayésiens

Apprentissage déterministe vs. bayésien

- **Les modèles déterministes** apprennent les paramètres $\mathbf{w}$ du modèle sur le jeu d'entraînement $\mathcal{D}$ en minimisant l'espérance de la loss $\mathcal{L}$:

$$\mathbf{w} = \underset{\mathbf{w}}{\operatorname{argmin}} \mathbb{E}_{(\mathbf{x}, \mathbf{y}) \sim p(\mathcal{D})} \mathcal{L}(f_{\mathbf{w}}(\mathbf{x}), \mathbf{y})$$


- **Les modèles bayésiens** apprennent la distribution de $\mathbf{w}$ conditionnellement au jeu d'entraînement $p(\mathbf{w}|\mathcal{D})$. Le meilleur modèle $\mathbf{w}^*$ est appelé maximum a posteriori (MAP) :

$$\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmin}} -\log p(\mathbf{w}|\mathcal{D})$$

Deep NN



Bayesian NN



Modèles bayésiens et incertitude

Distribution prédictive

À partir de la loi a posteriori $p(\mathbf{w}|\mathcal{D}) \Rightarrow$ calculer la **distribution prédictive** pour une nouvelle entrée $\mathbf{x}^*$:

$$\begin{aligned}\forall y, \quad p(y|\mathbf{x}^*, \mathcal{D}) &= \int \boxed{p(y, \mathbf{w}|\mathbf{x}^*, \mathcal{D})} d\mathbf{w} && \text{marginalisation} \\ &\quad \downarrow \text{Bayes} \\ &= \int \boxed{p(y|\mathbf{x}^*, \mathbf{w})} \boxed{p(\mathbf{w}|\mathcal{D})} d\mathbf{w} && \text{règle de Bayes} \\ &= \mathbb{E}_{p(\mathbf{w}|\mathcal{D})}[p(y|\mathbf{x}^*, \mathbf{w})] && \text{définition de l'espérance}\end{aligned}$$

À retenir


La prédiction n'est plus un point unique : on moyenne les sorties de modèles pondérés par leur probabilité a posteriori.

Modèles bayésiens et incertitude


Intuition visuelle

Plus la loi a posteriori est étalée, plus la distribution prédictive reflète l'incertitude sur le modèle.

Posterior Distribution of
Model Parameters





$$y = w_1 \cdot x + w_2$$



Modèles bayésiens et incertitude

Intuition visuelle


Plus la loi a posteriori est étalée, plus la distribution prédictive reflète l'incertitude sur le modèle.



Modèles bayésiens et incertitude

Intuition visuelle


Plus la loi a posteriori est étalée, plus la distribution prédictive reflète l'incertitude sur le modèle.



Modèles bayésiens et incertitude


Intuition visuelle

Plus la loi a posteriori est étalée, plus la distribution prédictive reflète l'incertitude sur le modèle.



Modèles bayésiens et incertitude

- RÉCAPITULATIF : pour estimer l'incertitude avec des modèles bayésiens
 - ❶ Définir l'a priori $p(\mathbf{w})$ et la vraisemblance $p(\mathbf{Y}/\mathbf{X}, \mathbf{w})$
 - ❷ Calculer la loi a posteriori $p(\mathbf{w}/\mathbf{X}, \mathbf{Y})$
 - ❸ Calculer la distribution prédictive $p(\mathbf{y}^*/\mathbf{x}^*, \mathbf{Y}, \mathbf{X})$
- Facile ? Non !! $\Rightarrow$ les étapes 2 et 3 sont en général coûteuses à calculer.
 - Typiquement pas d'expression analytique pour l'étape 2
 - Intégration en grande dimension pour l'étape 3



- 1 Inférence bayésienne
- 2 Exemple : Régression linéaire bayésienne**
- 3 Au-delà de la régression linéaire
- 4 Inférence variationnelle

Distributions conjuguées

Définition

Un prior est dit conjugué à une vraisemblance si le posterior appartient à la même famille que le prior.

$$p(w) \in \mathcal{F} \quad \text{et} \quad p(w|D) \in \mathcal{F}$$

- Conséquences :
 - calcul analytique du posterior
 - mise à jour simple des paramètres
- $\Rightarrow$ cas privilégié en pratique (mais rare)

Exemple : cas gaussien

- Modèle :

- Prior : $w \sim \mathcal{N}(0, \tau^2 I)$
- Likelihood : $x_i \sim \mathcal{N}(w, \sigma^2)$

- Posterior :

$$p(w|D) = \mathcal{N}(\mu_n, \Sigma_n)$$

- Interprétation :

- le posterior reste gaussien
- mise à jour des paramètres (μ_n, Σ_n)

- $\Rightarrow$ calcul exact possible

Exemple : cas gaussien

On a la formule suivante pour le calcul du posterior [Bishop, 2006]

- Supposons que :
 - $p(\mathbf{x}) = \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_x, \boldsymbol{\Sigma}_x)$
 - $p(\mathbf{y}|\mathbf{x}) = \mathcal{N}(\mathbf{y}|\mathbf{A}\mathbf{x} + b, \boldsymbol{\Sigma}_y)$
- Alors : $p(\mathbf{x}|\mathbf{y}) = \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_{x|\mathbf{y}}, \boldsymbol{\Sigma}_{x|\mathbf{y}})$, avec :

$$\boldsymbol{\Sigma}_{x|\mathbf{y}}^{-1} = \boldsymbol{\Sigma}_x^{-1} + \mathbf{A}^T \boldsymbol{\Sigma}_y^{-1} \mathbf{A}$$

$$\boldsymbol{\mu}_{x|\mathbf{y}} = \boldsymbol{\Sigma}_{x|\mathbf{y}} [\mathbf{A}^T \boldsymbol{\Sigma}_y^{-1} (\mathbf{y} - b) + \boldsymbol{\Sigma}_x^{-1} \boldsymbol{\mu}_x]$$


Rappel : régression linéaire

- N exemples d'entraînement $(\mathbf{x}_i, \mathbf{y}_i)_{i \in \{1;N\}}$; $\mathbf{x}_i \in \mathbb{R}^p$, $\mathbf{y}_i \in \mathbb{R}^K$
- Notation matricielle, biais inclus dans $\mathbf{w}$: Φ de taille $N \times (p+1)$

$$\Phi = \begin{pmatrix} 1 & x_{11} & \dots & x_{1p} \\ 1 & x_{21} & \dots & x_{2p} \\ \dots & \dots & \dots & \dots \\ 1 & x_{N1} & \dots & x_{Np} \end{pmatrix}$$



- $\mathbf{Y} = \Phi \mathbf{w} + \varepsilon$, $\varepsilon \in \mathbb{R}^{N \times K}$, $\varepsilon_{i,k} \sim \mathcal{N}(0, \sigma^2)$
- $\mathbf{Y} \in \mathbb{R}^{N \times K}$, $\Phi \in \mathbb{R}^{N \times (p+1)}$, $\mathbf{w} \in \mathbb{R}^{(p+1) \times K}$
 - $\Phi_i^T := (1 \ x_{i1} \ \dots \ x_{ip})^T \in \mathbb{R}^{1 \times (p+1)}$
 - $\mathbf{y}_i = \Phi_i^T \mathbf{w} + \varepsilon_i$, $\mathbf{y}_i \in \mathbb{R}^{1 \times K}$, $\varepsilon_i \in \mathbb{R}^{1 \times K}$

- Ex. : entrées et sorties scalaires $p = 1$, $K = 1 \Rightarrow \Phi \in \mathbb{R}^{N \times 2}$, $\mathbf{w} \in \mathbb{R}^2$:



Régression linéaire probabiliste

- N exemples d'entraînement $(\mathbf{x}_i, \mathbf{y}_i)$ avec $\mathbf{y}_i = \Phi_i^T \mathbf{w} + \varepsilon_i$, $\varepsilon_i \sim \mathcal{N}(0, 1)$
- $p(\mathbf{y}_i | \mathbf{x}_i, \mathbf{w}) \sim \mathcal{N}(\Phi_i^T \mathbf{w}, \sigma^2)$ or $p(\mathbf{y}_i - \Phi_i^T \mathbf{w}) \sim \mathcal{N}(0, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(\mathbf{y}_i - \Phi_i^T \mathbf{w})^2}{2\sigma^2}}$
 - $p(\mathbf{y}_i | \mathbf{x}_i, \mathbf{w})$: vraisemblance, $\sigma \sim$ incertitude aléatoire
 - σ indépendant de $\mathbf{x} \Rightarrow$ incertitude homoscédastique



Régression linéaire bayésienne

Apprentissage par maximum de vraisemblance

Les exemples sont supposés *i.i.d.* :

$$p(\mathbf{Y}/\mathbf{X}, \mathbf{w}, \sigma) = \prod_{i=1}^N p(y_i/x_i, \mathbf{w}, \sigma)$$

- On cherche

$$(\hat{\mathbf{w}}, \hat{\sigma}) = \arg \max_{(\mathbf{w}, \sigma)} p(\mathbf{X}, \mathbf{Y}/\mathbf{w}, \sigma)$$

- Ce problème revient à minimiser la log-vraisemblance négative :

$$(\hat{\mathbf{w}}, \hat{\sigma}) = \arg \min_{\mathbf{w}, \sigma} - \sum_{i=1}^N \log [p(\mathbf{y}_i/\mathbf{x}_i, \mathbf{w})]$$

Régression linéaire bayésienne

Solution pour les poids

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w}} \sum_{i=1}^N (\mathbf{y}_i - \Phi_i^T \mathbf{w})^2$$

$$\hat{\mathbf{w}} = (\Phi^T \Phi)^{-1} \Phi^T \mathbf{Y}$$

- On retrouve un problème de moindres carrés ordinaires.
- $C(\mathbf{w}) = \|\mathbf{Y} - \Phi \mathbf{w}\|^2$ et $\nabla_{\mathbf{w}} C = 0 \Leftrightarrow \Phi^T \Phi \mathbf{w} = \Phi^T \mathbf{Y}$.

Solution pour le bruit

$$\hat{\sigma}^2 = \frac{1}{N} \sum_{i=1}^N (\mathbf{y}_i - \Phi_i^T \mathbf{w})^2$$

Interprétation : variance résiduelle des données.

Limites du maximum de vraisemblance

- Apprendre un modèle pour prédire un lancer de pièce avec le maximum de vraisemblance

- Bernoulli variable X with param p : $P(\mathbf{x}|p) = \prod_{i=1}^N P(x_i|p) = \prod_{i=1}^N p^{x_i}(1-p)^{1-x_i}$

- MLE : $\ln P(\mathbf{x}|p) = \sum_{i=1}^N [x_i \ln p + (1-x_i) \ln(1-p)] \Rightarrow p_{MLE} = \frac{1}{N} \sum_{i=1}^N x_i$

- MLE prédit $P(X|p_{MLE}) = 1$ pour tous les futurs lancers !



- Utiliser une connaissance a priori sur p , e.g. $P(p) = 0.5$ ou $P(p) = 0.3 \Rightarrow$ MAP

Régression linéaire bayésienne

Idée centrale

Introduire un a priori $p(\mathbf{w})$ pour obtenir une loi a posteriori sur les paramètres, et non plus seulement une estimation ponctuelle.

- **A priori** : $p(\mathbf{w}|\alpha) = \mathcal{N}(\mathbf{w}; 0, \alpha^{-1}I)$
- **Vraisemblance** : $p(\mathbf{y}_i/\mathbf{x}_i, \mathbf{w}) = \mathcal{N}(\Phi_i^T \mathbf{w}, \beta^{-1})$
- **Loi a posteriori** :

$$p(\mathbf{w}/\mathbf{X}, \mathbf{Y}) \propto p(\mathbf{Y}/\mathbf{X}, \mathbf{w}) p(\mathbf{w})$$

- Ici, a priori et vraisemblance sont gaussiens : on est dans un cas **conjugué**.

Régression linéaire bayésienne


Forme fermée de la loi a posteriori

$$\begin{aligned} p(\mathbf{w}/\mathbf{X}, \mathbf{Y}) &= \mathcal{N}(\mathbf{w}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) \\ \boldsymbol{\Sigma}^{-1} &= \alpha \mathbf{I} + \beta \boldsymbol{\Phi}^T \boldsymbol{\Phi} \\ \boldsymbol{\mu} &= \beta \boldsymbol{\Sigma} \boldsymbol{\Phi}^T \mathbf{Y} \end{aligned}$$


- La solution MAP correspond au mode de cette gaussienne, donc à $\boldsymbol{\mu}$.
- $\alpha \rightarrow 0 \Rightarrow$ on retrouve le maximum de vraisemblance.
- $N = 0 \Rightarrow$ on retrouve l'a priori.

Régression linéaire bayésienne : échantillonnage a posteriori


- $p(\mathbf{w}/\mathbf{X}, \mathbf{Y}) = \mathcal{N}(\mathbf{w}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) \Rightarrow$ on peut échantillonner la loi a posteriori
 - Sans observation : $p(\mathbf{w}/\mathbf{X}, \mathbf{Y}) = p(\mathbf{w})$
 - $N \geq 1$: l'a priori est biaisé par la vraisemblance des données
 - Ex. : $p(\mathbf{w}|\mathbf{x}_0, \mathbf{y}_0) \propto p(\mathbf{w})p(\mathbf{y}_0|\mathbf{x}_0, \mathbf{w})$
 - $p(\mathbf{w} | (\mathbf{x}_0, \mathbf{y}_0), (\mathbf{x}_1, \mathbf{y}_1)) \propto p(\mathbf{w}|\mathbf{x}_0, \mathbf{y}_0)p(\mathbf{y}_1|\mathbf{x}_1, \mathbf{w}) \propto p(\mathbf{w})p(\mathbf{y}_0|\mathbf{x}_0, \mathbf{w})p(\mathbf{y}_1|\mathbf{x}_1, \mathbf{w}) \dots$



no observations




one observation



two observations

Régression linéaire bayésienne : échantillonnage a posteriori



0 data points are observed.

1 data point is observed.

2 data points are observed.

20 data points are observed.

Régression linéaire bayésienne : distribution prédictive

Principe

$$p(y|\mathbf{x}^*, \mathcal{D}, \alpha, \beta) = \int p(y|\mathbf{x}^*, \mathbf{w}, \beta) p(\mathbf{w}|\mathcal{D}, \alpha, \beta) d\mathbf{w}$$

- $p(y|\mathbf{x}^*, \mathbf{w}, \beta)$: vraisemblance conditionnelle
- $p(\mathbf{w}|\mathcal{D}, \alpha, \beta)$: loi a posteriori sur les paramètres
- On marginalise donc les prédictions sur toutes les valeurs plausibles de $\mathbf{w}$.

Conséquence

Comme on convole deux gaussiennes, la distribution prédictive reste gaussienne.

$$p(y|\mathbf{x}^*, \mathcal{D}, \alpha, \beta) = \mathcal{N}(y; \mu^T \Phi(\mathbf{x}^*), \frac{1}{\beta} + \Phi(\mathbf{x}^*)^T \Sigma \Phi(\mathbf{x}^*))$$

- 1 Inférence bayésienne
- 2 Exemple : Régression linéaire bayésienne
- 3 **Au-delà de la régression linéaire**
- 4 Inférence variationnelle

Au-delà de la régression linéaire bayésienne

- Loi a posteriori des paramètres $\mathbf{w}$: $p(\mathbf{w}|\mathbf{X}, \mathbf{Y}) \propto p(\mathbf{Y}|\mathbf{X}, \mathbf{w})p(\mathbf{w})$
- Distribution prédictive $p(y|\mathbf{x}^*, \mathcal{D}) = \int p(y|\mathbf{x}^*, \mathbf{w})p(\mathbf{w}|\mathcal{D})d\mathbf{w}$, $(\mathbf{X}, \mathbf{Y}) := \mathcal{D}$
- **Une expression analytique pour la loi a posteriori $p(\mathbf{w}|\mathcal{D})$ et la distribution prédictive $p(y|\mathbf{x}^*, \mathcal{D})$ est plutôt l'exception que la règle !**
- Des modèles légèrement plus complexes n'admettent plus d'expression analytique
 - Régression logistique bayésienne
 - Modèle de classification linéaire le plus simple
 - Vraisemblance non gaussienne
 - Réseau de neurones à une couche cachée en général
 - Pas d'expression analytique en régression comme en classification
 - Et bien sûr les réseaux de neurones profonds


Inférence approchée

En général, pas d'expression analytique pour la loi a posteriori $p(\mathbf{w}|\mathcal{D})$ ni pour $p(y|\mathbf{x}^*, \mathcal{D})$

⇒ **Approximation nécessaire !**

- **Approximation gaussienne de $p(\mathbf{w}|\mathcal{D})$**
 - Ex. : **approximation de Laplace** [MacKay, 1992]
 - Historiquement utilisée pour la régression logistique bayésienne
- **Méthodes de Monte Carlo** : échantillonnage pour évaluer directement l'intégrale $p(y|\mathbf{x}^*, \mathcal{D})$
 - **Metropolis-Hasting, Hamiltonian Monte Carlo** [Neal, 1996], **propagation d'espérance** [Hernandez-Lobato and Adams, 2015, Jylänki et al., 2014]
- **Inférence variationnelle** [Hinton and van Camp, 1993, Graves, 2011, Blundell et al., 2015] : transforme l'intégration en problème d'optimisation
 - Minimiser la divergence KL entre $p(\mathbf{w}|\mathcal{D})$ et une famille paramétrique proposée

Régression logistique bayésienne



- $s_i = \mathbf{W}\mathbf{x}_i$
- Cas multiclasse : $p(\mathbf{y}_i|\mathbf{x}_i, \mathbf{w}) = \hat{\mathbf{y}}_i$
 - $\hat{y}_{i,k} = \frac{\exp(s_i)}{\sum_k \exp(s_k)}$
- Cas binaire : $p(\mathbf{y}_i = 1|\mathbf{x}_i, \mathbf{w}) = \sigma(s_i)$
 - σ sigmoïde
 - $p(\mathbf{y}_i = -1|\mathbf{x}_i, \mathbf{w}) = 1 - \sigma(s_i)$

$$p(\mathbf{w}|\mathbf{X}, \mathbf{Y}) \propto p(\mathbf{Y}|\mathbf{X}, \mathbf{w})p(\mathbf{w})$$

- $p(\mathbf{Y}|\mathbf{X}, \mathbf{w}) = \prod_{i=1}^N p(\mathbf{y}_i = 1|\mathbf{x}_i, \mathbf{w})$ n'est plus gaussienne !

$\Rightarrow$ pas d'expression analytique pour la loi a posteriori $p(\mathbf{w}|\mathbf{X}, \mathbf{Y})$!

Régression logistique bayésienne (MAP)

Objectif MAP

$$\begin{aligned}\mathbf{w}_{\text{MAP}} &= \arg \max_{\mathbf{w}} p(\mathbf{X}, \mathbf{Y} | \mathbf{w}) p(\mathbf{w}) \\ &= \arg \min_{\mathbf{w}} \sum_{n=1}^N -\log(p(y_n | \mathbf{x}_n, \mathbf{w})) - \log(p(\mathbf{w}))\end{aligned}$$

- A priori gaussien : $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}; 0, \sigma_0^2 I)$
- Dans le cas binaire :

$$\begin{aligned}\mathbf{w}_{\text{MAP}} &= \arg \min_{\mathbf{w}} \sum_{n=1}^N \left(-y_n \log \sigma(\mathbf{w}^T \mathbf{x}_n + b) \right. \\ &\quad \left. - (1 - y_n) \log(1 - \sigma(\mathbf{w}^T \mathbf{x}_n + b)) + \frac{1}{2\sigma_0^2} \|\mathbf{w}\|_2^2 \right)\end{aligned}$$

- A priori gaussien $\Leftrightarrow$ pénalisation des poids

Régression logistique bayésienne (MAP)

Optimisation pratique

$$\mathbf{w}_{\text{MAP}} = \arg \min_{\mathbf{w}} \sum_{n=1}^N -\log(p(y_n|\mathbf{x}_n, \mathbf{w})) + \frac{1}{2\sigma_0^2} \|\mathbf{w}\|_2^2$$

- $\mathbf{w}_{\text{MAP}}$ s'obtient par descente de gradient.
- Mais pour faire une prédiction bayésienne, il faut en principe intégrer sur toute la loi a posteriori :

$$p(\mathbf{y} = 1|\mathbf{x}^*, \mathcal{D}) = \int p(\mathbf{y} = 1|\mathbf{x}^*, \mathbf{w}) p(\mathbf{w}|\mathcal{D}) d\mathbf{w}$$

Régression logistique bayésienne (MAP)

Approximation MAP

Il faut la loi a posteriori complète $p(\mathbf{w}|\mathbf{X}, \mathbf{Y})$, mais elle est intractable.


- Approximation la plus simple :

$$p(\mathbf{w}|\mathbf{X}, \mathbf{Y}) \approx \delta(\mathbf{w} - \mathbf{w}_{\text{MAP}})$$


- On remplace alors l'intégrale prédictive par une simple évaluation au MAP :

$$p(y = 1|\mathbf{x}^*, \mathcal{D}) \approx p(y = 1|\mathbf{x}^*, \mathbf{w}_{\text{MAP}})$$

Approximating Distribution with its Maximum A Posteriori



Régression logistique bayésienne (MAP)




Limites du MAP

- $p(\mathbf{w}|\mathbf{X}, \mathbf{Y}) \approx \delta(\mathbf{w} - \mathbf{w}_{\text{MAP}})$: approximation très grossière
- L'incertitude n'augmente pas loin des données d'entraînement
- Il faut donc des approximations plus riches

Approximation de Laplace pour $p(\mathbf{w}|\mathbf{X}, \mathbf{Y})$

- Approximer $p(\mathbf{w}|\mathbf{X}, \mathbf{Y})$ par une loi normale $q(\mathbf{w}) = \mathcal{N}(\mathbf{w}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$
- Ajuster la moyenne $\boldsymbol{\mu}$ de $q(\mathbf{w})$ sur le mode de $p(\mathbf{w}|\mathbf{X}, \mathbf{Y})$
↪ Faire coïncider le maximum de la gaussienne avec le maximum de la loi a posteriori
- Ajuster l'inverse de la covariance $\boldsymbol{\Sigma}^{-1}$ de $q(\mathbf{w})$ sur la Hessienne de $p(\mathbf{w}|\mathbf{X}, \mathbf{Y})$ en $\boldsymbol{\mu} = \mathbf{w}_{MAP}$
↪ Faire correspondre la variance à la courbure autour du maximum



from [Bishop, 2006]

- Limite de Laplace : approximation en une seule valeur de $p(\mathbf{w}|\mathbf{X}, \mathbf{Y})$, qui ignore les propriétés globales

Distribution prédictive $p(y|\mathbf{x}^*, \mathcal{D})$ pour la BLR

RÉCAPITULATIF, avec $\mathcal{D} = \mathbf{X}, \mathbf{Y}$:

$$p(y|\mathbf{x}^*, \mathcal{D}) = \int p(y|\mathbf{x}^*, \mathbf{w})p(\mathbf{w}|\mathcal{D})d\mathbf{w}$$

- Approximation gaussienne de la loi a posteriori
 $p(\mathbf{w}|\mathcal{D}) \approx q(\mathbf{w}) = \mathcal{N}(\mathbf{w}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$:

$$p(y|\mathbf{x}^*, \mathcal{D}) \approx \int p(y|\mathbf{x}^*, \mathbf{w})q(\mathbf{w})d\mathbf{w}$$

- Cependant, la distribution prédictive $p(y|\mathbf{x}^*, \mathcal{D})$ reste non gaussienne

$\Rightarrow$ **Distribution prédictive $p(y|\mathbf{x}^*, \mathcal{D})$ intractable !**



Distribution prédictive $p(y|\mathbf{x}^*, \mathcal{D})$ pour la BLR

- **Estimation** : utiliser un échantillonnage de Monte Carlo (MC)

- Cas binaire (extension multiclass simple) : $p(y = 1|\mathbf{x}^*, \mathbf{w}) = \sigma(\mathbf{w}^T \mathbf{x}^*)$, σ sigmoïde

$$p(y = 1|\mathbf{x}^*, \mathcal{D}) \approx \sum_{s=1}^S \sigma\left((\mathbf{w}^s)^T \mathbf{x}^*\right) \quad \mathbf{w}^s \sim q(\mathbf{w}) = \mathcal{N}(\mathbf{w}; \boldsymbol{\mu}, \boldsymbol{\Sigma})$$

- Échantillonnage facile depuis la gaussienne $q(\mathbf{w})$



- 1 Inférence bayésienne
- 2 Exemple : Régression linéaire bayésienne
- 3 Au-delà de la régression linéaire
- 4 Inférence variationnelle**

Inférence variationnelle (VI)

La vraie loi a posteriori $p(\mathbf{w}|\mathbf{X}, \mathbf{Y})$ ne peut généralement pas être calculée analytiquement

- Définir une **distribution variationnelle approchée** $q_{\theta}(\mathbf{w})$, paramétrée par θ
- **Minimiser sa divergence de KL avec la vraie loi a posteriori** :

$$KL(q_{\theta}(\mathbf{w})||p(\mathbf{w}|\mathbf{X}, \mathbf{Y})) = \int q_{\theta}(\mathbf{w}) \log \frac{q_{\theta}(\mathbf{w})}{p(\mathbf{w}|\mathbf{X}, \mathbf{Y})} d\mathbf{w}$$

- **Calculer une distribution prédictive approchée** : $p(\mathbf{w}|\mathbf{X}, \mathbf{Y}) \Leftarrow q_{\theta^*}(\mathbf{w})$:

$$p(\mathbf{y}|\mathbf{x}^*, \mathbf{X}, \mathbf{Y}) \approx \int p(\mathbf{y}|\mathbf{x}^*, \mathbf{w}) q_{\theta^*}(\mathbf{w}) d\mathbf{w}$$

Inférence variationnelle (VI)

- Avec un a priori, e.g. gaussien : $p(\mathbf{w}) = \mathcal{N}(\mathbf{w}|0, \alpha^{-1}\mathcal{I})$
- **Loi a posteriori variationnelle approchée** $q_{\theta}(\mathbf{w})$, e.g. gaussienne :

$$q_{\theta}(\mathbf{w}) = \mathcal{N}(\mathbf{w}|\theta) = \mathcal{N}(\mathbf{w}|\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

Inférence variationnelle (VI) : de KL à l'ELBO

$$\begin{aligned} KL(q_{\theta}(\mathbf{w})||p(\mathbf{w}|\mathbf{X}, \mathbf{Y})) &= \int q_{\theta}(\mathbf{w}) \log \frac{q_{\theta}(\mathbf{w})}{p(\mathbf{w}|\mathbf{X}, \mathbf{Y})} d\mathbf{w} = - \int q_{\theta}(\mathbf{w}) \log \frac{p(\mathbf{w}|\mathbf{X}, \mathbf{Y})}{q_{\theta}(\mathbf{w})} d\mathbf{w}^1 \\ &= - \int q_{\theta}(\mathbf{w}) \log \frac{p(\mathbf{Y}|\mathbf{X}, \mathbf{w})p(\mathbf{w})}{q_{\theta}(\mathbf{w})p(\mathbf{Y}|\mathbf{X})} d\mathbf{w} \\ &= - \int q_{\theta}(\mathbf{w}) \log p(\mathbf{Y}|\mathbf{X}, \mathbf{w}) d\mathbf{w} + \int q_{\theta}(\mathbf{w}) \log \frac{q_{\theta}(\mathbf{w})}{p(\mathbf{w})} + \log p(\mathbf{Y}|\mathbf{X}) \\ &= - \int q_{\theta}(\mathbf{w}) \log p(\mathbf{Y}|\mathbf{X}, \mathbf{w}) d\mathbf{w} + KL(q_{\theta}(\mathbf{w})||p(\mathbf{w})) + \log p(\mathbf{Y}|\mathbf{X}) \end{aligned}$$

Conséquence immédiate

$$KL(q_{\theta}(\mathbf{w})||p(\mathbf{w}|\mathbf{X}, \mathbf{Y})) = -\mathcal{L}_{VI}(\mathbf{X}, \mathbf{Y}, \theta) + \log p(\mathbf{Y}|\mathbf{X})$$

1. $p(\mathbf{w}|\mathbf{X}, \mathbf{Y}) = \frac{p(\mathbf{Y}|\mathbf{X}, \mathbf{w})p(\mathbf{w})}{p(\mathbf{Y}|\mathbf{X})}$

Inférence variationnelle (VI) : définition de l'ELBO

- L'ELBO (Evidence Lower BOund) correspond à la quantité que l'on maximise quand on cherche une bonne approximation variationnelle.

Définition

$$\mathcal{L}_{VI}(\theta) = \int q_{\theta}(\mathbf{w}) \log p(\mathbf{Y}|\mathbf{X}, \mathbf{w}) d\mathbf{w} - KL(q_{\theta}(\mathbf{w})||p(\mathbf{w}))$$

- $\mathcal{L}_{VI}(\mathbf{X}, \mathbf{Y}, \theta)$: borne inférieure de la vraisemblance.
- En effet :


$$\mathcal{L}_{VI}(\theta) = \log p(\mathbf{Y}|\mathbf{X}) - KL(q_{\theta}(\mathbf{w})||p(\mathbf{w}|\mathbf{X}, \mathbf{Y})) \leq \log p(\mathbf{Y}|\mathbf{X})$$

Illustration de l'ELBO

- $\mathcal{L}_{VI}(\mathbf{X}, \mathbf{Y}, \theta)$: borne inférieure de l'évidence (ELBO)

$$\mathcal{L}_{VI}(\theta) = \int q_{\theta}(\mathbf{w}) \log p(\mathbf{Y}|\mathbf{X}, \mathbf{w}) d\mathbf{w} - KL(q_{\theta}(\mathbf{w})||p(\mathbf{w}))$$

- $\mathcal{L}_{VI}(\theta) = \log p(\mathbf{Y}|\mathbf{X}) - KL(q_{\theta}(\mathbf{w})||p(\mathbf{w}|\mathbf{X}, \mathbf{Y})) \leq \log p(\mathbf{Y}|\mathbf{X})$



Inférence variationnelle (VI) : ELBO

- $\mathcal{L}_{VI}(\theta) = \log p(\mathbf{Y}|\mathbf{X}) - KL(q_{\theta}(\mathbf{w})||p(\mathbf{w}|\mathbf{X}, \mathbf{Y}))$
- Minimiser $KL(q_{\theta}(\mathbf{w})||p(\mathbf{w}|\mathbf{X}, \mathbf{Y}))$ revient à maximiser $\mathcal{L}_{VI}(\theta)$ par rapport à $q_{\theta}(\mathbf{w})$:

$$\begin{aligned}\mathcal{L}_{VI}(\theta) &= \int q_{\theta}(\mathbf{w}) \log p(\mathbf{Y}|\mathbf{X}, \mathbf{w}) d\mathbf{w} - KL(q_{\theta}||p(\mathbf{w})) \leq \log p(\mathbf{Y}|\mathbf{X}) \\ &= \underbrace{\mathbb{E}_{q_{\theta}(\mathbf{w})}[\log p(\mathbf{Y}|\mathbf{X}, \mathbf{w})]}_{\text{Espérance de la Log-vraisemblance}} - \underbrace{KL(q_{\theta}(\mathbf{w})||p(\mathbf{w}))}_{\text{Divergence à l'a priori}}\end{aligned}$$

- **Espérance de la Log-vraisemblance** : pousse $q_{\theta}(\mathbf{w})$ à bien expliquer les données.
- **KL vers l'a priori** : force $q_{\theta}(\mathbf{w})$ à rester simple et proche de $p(\mathbf{w})$.

Inférence variationnelle : un problème encore difficile

- Objectif :

$$q^*(w) = \arg \min_q \text{KL}(q(w) \| p(w|D))$$

- Problème :

- Optimisation sur **toutes les distributions possibles**
- Espace fonctionnel très complexe

- Idée clé :

Restreindre la famille de distributions $q(w)$

Approximation de champ moyen

- Hypothèse :

$$q(w) = \prod_{i=1}^d q_i(w_i)$$

- Les variables sont supposées **indépendantes**
- Exemples :

- $q(w) = \prod_{i=1}^d \mathcal{N}(w_i | \mu_i, \sigma_i^2)$
- $q(w) = \prod_{i=1}^d \text{Bernoulli}(w_i | p_i)$

- Conséquences :
 - Réduction drastique de la complexité
 - Optimisation plus simple

- Intuition :

On approxime une distribution complexe par une distribution factorisée

Intuition et limites du champ moyen

- Avantages :
 - Calcul efficace
 - Passage à l'échelle
- Limite principale :
 - Ignore les corrélations entre variables
- Effet typique :
 - Sous-estimation de l'incertitude
- Idée clé :

Un compromis entre expressivité et tractabilité

Mean-field et optimisation

- Approximation :

$$q(x) = \prod_i q_i(x_i)$$

- Optimisation de l'ELBO :

$$\max_q \mathcal{L}(q)$$

- Résultat :

Mise à jour coordonnée :

$$\log q_j(x_j) = \mathbb{E}_{q_{-j}}[\log p(x)] + \text{const}$$

- $\Rightarrow$ Coordinate ascent sur l'ELBO

Conséquences du mean-field

- **Optimisation**

- algorithme itératif simple
- convergence monotone (ELBO)

- **Complexité**

- dépend du Markov blanket
- scalable

- **Biais**

- indépendance forcée
- sous-estimation de l'incertitude

- **$KL(q||p)$**

- mode-seeking
- ignore certaines régions de p



Bishop, C. M. (2006).

Pattern Recognition and Machine Learning (Information Science and Statistics).
Springer-Verlag, Berlin, Heidelberg.



Blundell, C., Cornebise, J., Kavukcuoglu, K., and Wierstra, D. (2015).

Weight uncertainty in neural network.

In Bach, F. and Blei, D., editors, Proceedings of the 32nd International Conference on Machine Learning, volume 37 of Proceedings of Machine Learning Research, pages 1613–1622, Lille, France. PMLR.



Graves, A. (2011).

Practical variational inference for neural networks.

In Shawe-Taylor, J., Zemel, R. S., Bartlett, P. L., Pereira, F., and Weinberger, K. Q., editors, Advances in Neural Information Processing Systems 24, pages 2348–2356. Curran Associates, Inc.



Hernandez-Lobato, J. M. and Adams, R. (2015).

Probabilistic backpropagation for scalable learning of bayesian neural networks.

In Bach, F. and Blei, D., editors, Proceedings of the 32nd International Conference on Machine Learning, volume 37 of Proceedings of Machine Learning Research, pages 1861–1869, Lille, France. PMLR.



Hinton, G. E. and van Camp, D. (1993).

Keeping the neural networks simple by minimizing the description length of the weights.

In Proceedings of the Sixth Annual Conference on Computational Learning Theory, COLT '93, pages 5–13, New York, NY, USA. ACM.



Jylänki, P., Nummenmaa, A., and Vehtari, A. (2014).

Expectation propagation for neural networks with sparsity-promoting priors.

Journal of Machine Learning Research, 15 :1849–1901.



MacKay, D. J. C. (1992).

A practical bayesian framework for backpropagation networks.

Neural Comput., 4(3) :448–472.



Murphy, K. P. (2012).

Machine Learning : A Probabilistic Perspective.
[The MIT Press.](#)



Neal, R. M. (1996).

Bayesian Learning for Neural Networks.
[Springer-Verlag, Berlin, Heidelberg.](#)