

TD 6 - Apprentissage non supervisé

Exercice 1 – Clustering Spectral

On considère un graphe non orienté $G = (V, E)$ de n sommets, $V = \{v_1, \dots, v_n\}$. On lui associe $W = (w_{ij})_{i,j=1,\dots,n}$, $w_{ij} \geq 0$ une matrice de poids non négative (symétrique). Les nœuds de ce graphe représentent les exemples à clusteriser, les poids représentent les similarités entre exemples : plus un poids entre deux nœuds est fort, plus les deux exemples associés sont similaires. Un des avantages du clustering spectral est donc de fonctionner sur une notion de similarité (comme les noyaux dans les SVMs) et non pas uniquement géométriquement sur une description euclidienne de nos exemples. Bien sûr, toute description euclidienne peut être représentée par une similarité (prendre l'exponentiel de l'inverse de la distance par exemple). Le principe du clustering spectral est de former des partitions de telle manière que les nœuds dans une même partition aient une connectivité très forte (les poids au sein de chaque cluster doivent être très élevés) et que les poids inter-clusters soient le plus faible possible - qu'il y ait une faible connectivité entre les sommets de deux clusters disjoints. En langage graphe, il s'agit de faire un partitionnement du graphe tel que la *coupe* associée fasse disparaître les connexions de poids le plus faible possible.

La mesure de qualité d'une coupe en k partitions $A_1, \dots, A_k$ est définie par :

$$Rcut(A_1, \dots, A_k) = \frac{1}{2} \sum_{i=1}^k \frac{W(A_i, \bar{A}_i)}{|A_i|}$$

avec $W(A, B) = \sum_{i \in A, j \in B} w_{ij}$, $\bar{A}$ le complément de A dans V et $|A|$ le nombre de sommets de A . Le clustering spectral cherche donc à résoudre : $\min_{A_1, \dots, A_k} Rcut(A_1, \dots, A_k)$ avec $A_1, \dots, A_k$ une partition des sommets de V .

L'algorithme se base sur la notion de Laplacien d'un graphe : soit W la matrice des poids et $D = (d_i)_{i=1\dots n}$ la matrice diagonale telle que $d_i = \sum_{j=1}^n w_{ij}$, le Laplacien du graphe est la matrice $L = D - W$. Le but de l'exercice est d'examiner une interprétation en terme de partitionnement de graphe.

Rappel d'algèbre linéaire : Une matrice $M \in \mathbb{R}^{d \times d}$ symétrique est dite semi-définie positive si elle vérifie entre autre l'une de ces propriétés (équivalentes) :

- $\forall \mathbf{x} \in \mathbb{R}^d, \mathbf{x}^T M \mathbf{x} \geq 0$
- toutes les valeurs propres sont non-négatives

On appelle vecteur propre $v \in \mathbb{R}^d$ et valeur propre $\lambda \in \mathbb{R}$ un vecteur et un réel tels que $Mv = \lambda v$. Toute matrice symétrique A réelle admet d vecteurs propres indépendants. A est donc diagonalisable : $A = Q^T \Lambda Q$ avec Q matrice orthogonale composée des vecteurs propres orthogonaux et unitaires ($\|q_i\|^2 = 1$ et $\forall i, j, q_i \cdot q_j = 0$), et Λ diagonale avec comme éléments les valeurs propres associées aux vecteurs propres.

Q 1.1 On démontre tout d'abord quelques propriétés du Laplacien que l'on utilisera à la fin de l'exercice.

Montrer que :

Q 1.1.1 $\forall \mathbf{x} \in \mathbb{R}^n, \mathbf{x}^T L \mathbf{x} = \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n w_{ij} (x_i - x_j)^2$

Q 1.1.2 L est symétrique et positive semi-définie.

Q 1.1.3 la plus petite valeur propre de L est 0 et le vecteur propre associé est le vecteur $e = (1, \dots, 1)^T$ de taille n .

Q 1.2 On considère le cas de la séparation en 2 clusters A et $\bar{A}$, avec $k = 2$. L'objectif est de ramener l'écriture $\min_{A \subset V} Rcut(A, \bar{A})$ à un problème d'optimisation continue.

Soit $\mathbf{x} \in \mathbb{R}^n$ tel que $x_i = \sqrt{\frac{|\bar{A}|}{|A|}}$ si $x_i \in A$, et $x_i = -\sqrt{\frac{|\bar{A}|}{|A|}}$ si $x_i \in \bar{A}$. La valeur de x_i permet donc d'indiquer si le nœud i appartient au premier ou au deuxième cluster. Le vecteur $\mathbf{x}$ permet d'encoder ainsi tous les partitionnements possibles en deux clusters.

Montrer que

Q 1.2.1 $\mathbf{x}^T L \mathbf{x} = n \cdot Rcut(A, \bar{A})$

Q 1.2.2 $\mathbf{x}^T \cdot e = \sum_{i=1}^n x_i = 0$

Q 1.2.3 $\|\mathbf{x}\|^2 = \mathbf{x}^T \mathbf{x} = n$. Comment interprétez vous cette contrainte et celle de la question précédente ?

On vient de montrer que le problème $\min_{A \subset V} Rcut(A, \bar{A})$ est équivalent à $\min_{\mathbf{x} \in \mathbb{R}^n} \mathbf{x}^T L \mathbf{x}$ sous la contrainte d'un vecteur $\mathbf{x}$ encodant le partitionnement : $\mathbf{x} = (x_1, \dots, x_N)$, avec $x_i = \alpha$ ou $x_i = \beta$, avec $\alpha = \sqrt{\frac{|\bar{A}|}{|A|}}$ et $\beta = -\sqrt{\frac{|\bar{A}|}{|A|}}$. Les constantes α et β peuvent être quelconques, bien choisies elle permettent d'équilibrer le partitionnement et d'obtenir exactement la mesure de coût $Rcut$.

Ce problème est NP-difficile : il s'agit de choisir de manière combinatoire la bonne affectation de chacun des nœuds dans une des deux partitions. Afin de le relaxer et de pouvoir le traiter par une optimisation continue, on va supprimer la contrainte sur le vecteur $\mathbf{x}$ tout en introduisant les deux contraintes $\mathbf{x}^T \mathbf{x} = n$ et $\mathbf{x}^T \cdot e = 0$ pour garantir des solutions pas trop éloignées de notre optimum discret.

Q 1.3 Considérons le problème d'optimisation $\min_{\mathbf{x} \in \mathbb{R}^n} \mathbf{x}^T L \mathbf{x}$ sous la contrainte $\mathbf{x}^T \mathbf{x} = n$. Montrer que la solution à ce problème est un vecteur propre $e^{(i)}$ de L et que pour ce vecteur $e^{(i)T} L e^{(i)} = n \lambda_i$ avec λ_i la valeur propre associée à $e^{(i)}$ (utiliser $\nabla_{\mathbf{x}} \mathbf{x}^T \mathbf{x} = 2\mathbf{x}$ et $\nabla_{\mathbf{x}} \mathbf{x}^T A \mathbf{x} = (A + A^T)\mathbf{x}$). En déduire la solution du problème.

Q 1.4 On considère le problème d'optimisation $\min_{\mathbf{x} \in \mathbb{R}^n} \mathbf{x}^T L \mathbf{x}$ sous les contraintes $\mathbf{x}^T \mathbf{x} = n$ et $\mathbf{x}^T e = 0$. En se servant de la question précédente, donner (sans calculs) la solution à ce problème. On notera e' ce vecteur.

Q 1.5 Comment se servir du vecteur propre e' pour construire une solution au problème de clustering pour $k = 2$?

Pour info, l'algorithme dans le cas général est le suivant avec k le nombre de clusters désiré. La démonstration est quasiment la même que dans le cas $k = 2$ mais en introduisant autant de vecteurs indicateurs d'appartenance de clusters que de clusters :

- Calculer le Laplacien L
- Calculer les k premiers vecteurs propres de L
- Soit $U \in \mathbb{R}^{n \times k}$ la matrice contenant les k vecteurs propres $u_1, \dots, u_k$ en colonne
- Pour $i = 1 \dots n$, soit $y_i \in \mathbb{R}^k$ le vecteur correspondant à la i -ème ligne de U
- Réaliser un clustering des $(y_i)_{i=1 \dots n}$ dans $\mathbb{R}^k$ avec un algorithme de k -means, on note $C_1, \dots, C_k$ les clusters obtenus.
- les clusters de sortie sont $A_1, \dots, A_k$ avec $A_i = \{v_j \in V | y_j \in C_i\}$

Pour plus de détails, vous pouvez regarder :cet article.