

TD 10

Exercice 1 – Inférence bayésienne avec prior conjugué

On considère un ensemble de données i.i.d.

$$X = \{x_i\}_{i=1,\dots,N}, \quad x_i \in \mathbb{R}, \quad \text{et tel que} \quad x_i \mid \mu \sim \mathcal{N}(\mu, \sigma^2),$$

où σ^2 est supposée connue. On place sur μ le prior gaussien :

$$\mu \sim \mathcal{N}(\mu_0, \lambda^2).$$

Le but de cet exercice est de comprendre les comportements limites des distributions a posteriori et predictive en fonction du prior et des données.

On note

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i, \quad \tau = \frac{1}{\sigma^2}, \quad \tau_0 = \frac{1}{\lambda^2}.$$

Dans ce modèle, le prior est conjugué à la vraisemblance et admet donc une forme analytique :

$$p(\mu \mid X) = \mathcal{N}(\mu_N, \tau_N^{-1}), \quad \text{avec} \quad \tau_N = \tau_0 + N\tau, \quad \mu_N = \frac{\tau_0\mu_0 + N\tau\bar{x}}{\tau_0 + N\tau}.$$

On admet également que la distribution prédictive pour une nouvelle observation $\tilde{x}$ est

$$p(\tilde{x} \mid X) = \mathcal{N}(\mu_N, \sigma^2 + \tau_N^{-1}).$$

Q 1.1 Écrire la loi de Bayes donnant $p(\mu \mid X)$. Quelle est en général la difficulté principale pour calculer cette quantité ?

Q 1.2 Montrer que la moyenne a posteriori μ_N peut s'écrire comme une combinaison convexe de μ_0 et de $\bar{x}$. Interpréter le rôle relatif du prior et des données.

Q 1.3 Donner le paramètre μ_{MAP} maximisant $p(\mu \mid X)$. Comparer μ_{MAP} à la moyenne a posteriori. Peut-on estimer la distribution predictive avec le MAP et quelles en sont les limites ?

Q 1.4 Interpréter les termes de la variance de la distribution prédictive. Étudier également les comportements limites de μ_N et de la variance a posteriori τ_N^{-1} suivants :

- $N \rightarrow \infty$,
- $\lambda^2 \rightarrow \infty$ (prior peu informatif),
- $\sigma^2 \rightarrow \infty$.

Exercice 2 – Divergence de Kullback–Leibler

Soient p et q deux distributions de probabilité définies sur un espace $\mathcal{X}$.

La divergence de Kullback–Leibler est définie par

$$\text{KL}(q\|p) = \mathbb{E}_q \left[\log \frac{q(x)}{p(x)} \right] = \int q(x) \log \frac{q(x)}{p(x)} dx.$$

Q 2.1 Montrer que

$$\text{KL}(q\|p) \geq 0.$$

Indication : utiliser l'inégalité de Jensen pour une fonction φ concave :

$$\mathbb{E}[\varphi(X)] \leq \varphi(\mathbb{E}[X]).$$

Q 2.2 Montrer que

$$\text{KL}(q\|p) = 0 \iff q = p \text{ (presque partout).}$$

Q 2.3 Montrer que la divergence de KL n'est pas symétrique, c'est-à-dire que, en général,

$$\text{KL}(q\|p) \neq \text{KL}(p\|q).$$

Q 2.4 On considère maintenant une distribution p multimodale, par exemple une somme de deux gaussiennes bien séparées. On souhaite trouver une approximation q de p en minimisant la divergence de KL. Comparer qualitativement les solutions obtenues en minimisant $\text{KL}(q\|p)$ et $\text{KL}(p\|q)$. Faire une figure illustrant les deux comportements. Donner une raison pratique pour laquelle on choisit généralement d'optimiser $\text{KL}(q\|p)$ plutôt que $\text{KL}(p\|q)$ en ML.

Exercice 3 – Inférence variationnelle mean-field

On considère le modèle suivant

$$p(x, z) = p(x|z)p(z),$$

où $z = (z_1, z_2)$ est une variable latente.

On souhaite approximer la distribution a posteriori $p(z|x)$ par une distribution factorisée :

$$q(z) = q_1(z_1) q_2(z_2).$$

On définit l'ELBO :

$$\mathcal{L}(q) = \mathbb{E}_q[\log p(x, z)] - \mathbb{E}_q[\log q(z)].$$

Q 3.1 Montrer que maximiser l'ELBO est équivalent à minimiser

$$\text{KL}(q(z)\|p(z|x)).$$

Q 3.2 En supposant q_2 fixé, on souhaite montrer que l'optimum en q_1 vérifie :

$$\log q_1(z_1) = \mathbb{E}_{q_2}[\log p(x, z)] + \text{const.}$$

Q 3.2.1 Montrer que maximiser l'ELBO peut s'écrire comme un problème d'optimisation de la forme

$$\max_{q_1} \int q_1(z_1) f(z_1) dz_1 - \int q_1(z_1) \log q_1(z_1) dz_1$$

sous la contrainte

$$\int q_1(z_1) dz_1 = 1.$$

Q 3.2.2 Poser le Lagrangien $J(q_1, \lambda)$ associé à ce problème d'optimisation

Q 3.2.3 On admet que la dérivée fonctionnelle de J par rapport à q_1 est donnée par

$$\frac{\delta J}{\delta q_1(z_1)} = f(z_1) - (\log q_1(z_1) + 1) + \lambda.$$

En déduire la relation vérifiée par $\log q_1(z_1)$ à l'optimum.

Q 3.3 Donner l'expression analogue pour q_2 .

Q 3.4 Quel type d'algorithme cela suggère-t-il ?