

TD 9 - Programmation dynamique

Notations et rappels : On note $\Pi(X)$ l'ensemble des distributions de probabilités sur un espace X .

Un MDP est défini par un ensemble d'états $\mathcal{S}$, un ensemble d'actions $\mathcal{A}$, une fonction de transition $T : \mathcal{S} \times \mathcal{A} \rightarrow \Pi(\mathcal{S})$ et une fonction de récompense $r : \mathcal{S} \times \mathcal{A} \times \mathcal{S} \rightarrow \mathbb{R}$. Par commodité, on note $p(s'|a, s) = T(s, a, s')$ la probabilité d'arriver en s' à partir de s en prenant l'action a . On ajoute parfois un *discount factor* γ et/ou une distribution sur les états initiaux ρ_0 .

Une politique stochastique $\pi : \mathcal{S} \rightarrow \Pi(\mathcal{A})$ régit le comportement d'un agent et attribue à cet agent une probabilité $\pi(a|s)$ de choisir une action a dans tout état s .

Un agent doté d'une politique π en interaction avec un MDP qui représente son environnement produit des trajectoires $\tau^\pi = \{s_0, a_0, r_1, s_1, a_2, r_2, \dots\}$ avec $r_{t+1} = r(s_t, a_t, s_{t+1})$ ¹. Ces trajectoires peuvent être infinies ou limitées par un horizon H . On note $R(\tau)$ l'utilité (*return* en anglais) d'une trajectoire τ , calculée dans le cas "actualisé" (*discounted* en anglais) comme $R(\tau) = \sum_{t \geq 0} \gamma^t r_{t+1}$.

La fonction de valeur de l'état s en fonction de la politique π est définie par $V^\pi(s) = \mathbb{E}_{\tau \sim \pi}[R(\tau) | s_0 = s]$. De façon similaire, la fonction de valeur d'action $Q^\pi(s, a) = \mathbb{E}_{\tau \sim \pi}[R(\tau) | s_0 = s, a_0 = a]$ définit la valeur d'être dans l'état s et de faire l'action a puis de suivre la politique π .

On définit aussi la fonction de valeur optimale $V^*(s) = \max_\pi V^\pi(s)$ et la fonction de valeur d'action optimale $Q^*(s, a) = \max_\pi Q^\pi(s, a)$.

L'objectif général de ce TD est de montrer que les algorithmes *value iteration* et *policy iteration* convergent vers des fonctions de valeur et de valeur d'action optimales.

Exercice 1 – Opérateur de Bellman, évaluation d'une politique et *policy iteration*

Q 1.1 Quels sont les liens entre Q^π et V^π , dans le cas où la politique π est respectivement déterministe et stochastique ?

Q 1.2 Dans le cas stochastique, montrer que

$$\begin{aligned} V^\pi(s) &= \sum_a \pi(a|s) \sum_{s'} p(s'|s, a) [r(s, a, s') + \gamma V^\pi(s')] \\ &= \mathbb{E}_{a \sim \pi, s_{t+1} \sim p(\cdot | s_t, a_t)} [r(s, a, s') + \gamma V^\pi(s')]. \end{aligned}$$

Q 1.3 On appelle opérateur de Bellman T^π l'opérateur

$$V_{k+1}(s) = (T^\pi V_k)(s) = \sum_a \pi(a|s) \sum_{s'} p(s'|s, a) [r(s, a, s') + \gamma V_k(s')].$$

Montrer la propriété de monotonie de l'opérateur : si $\forall s, V_1(s) \leq V_2(s)$, alors $\forall s$ on a : $T^\pi V_1(s) \leq T^\pi V_2(s)$.

Q 1.4 Montrer que l'application répétée de l'opérateur de Bellman sur un ensemble de valeurs V fait converger cet ensemble de valeurs vers un point fixe.

Q 1.5 L'algorithme *policy iteration* travaille, à chaque itération k , en deux temps :

1. Évaluation de V^{π_k} jusqu'à convergence selon la politique courante stationnaire π_k .
2. Mise à jour de la politique π_{k+1} selon une stratégie gloutonne (*greedy*) :

$$\forall s, \pi_{k+1}(s) = \operatorname{argmax}_a \sum_{s'} p(s'|s, a) [r(s, a, s') + \gamma V^{\pi_k}(s')]$$

¹. On utilise plus fréquemment $r_{t+1} = r(s_t, a_t)$ pour que la récompense ne dépende pas d'une transition stochastique. On utilise aussi parfois $r_{t+1} = r(s_t)$ quand cette modélisation correspond mieux à la nature du problème qu'on veut résoudre.

Déduire de la propriété de monotonie démontrée à la question précédente la convergence de *policy iteration*.

Exercice 2 – Opérateur d’optimalité de Bellman et *value iteration*

Q 2.1 Montrer l’équation d’optimalité de Bellman :

$$V^*(s) = \max_{\pi} V^{\pi}(s) = \max_a \sum_{s'} p(s'|s, a) [r(s, a, s') + \gamma V^*(s')].$$

Q 2.2 On appelle opérateur d’optimalité de Bellman T^* l’opérateur :

$$\forall s, (T^* V)(s) = \max_a \sum_{s'} p(s'|s, a) [r(s, a, s') + \gamma V(s')].$$

Soient deux ensembles de valeurs V_1 et V_2 définis pour tout état s . Montrer que

$$\|T^*V_1 - T^*V_2\|_{\infty} \leq \gamma \|V_1 - V_2\|_{\infty}.$$

Q 2.3 L’algorithme *value iteration* applique, pendant un nombre donné d’itérations, l’opérateur d’optimalité de Bellman pour mettre à jour les valeurs des états : $V^{(k+1)} = T^*V^{\pi_k}$, avec V^{π_k} l’ensemble des valeurs à l’itération k . Déduire de la propriété de contraction démontrée à la question précédente la convergence de cet algorithme (en supposant la propriété de point fixe $TV^* = V^*$).