

RITAL – Examen réparti – 28/04/2025 – 40 pts

Durée : 2h

Seuls documents autorisés : *une page de note A4 recto-verso manuscrite*
– Barème indicatif –

1 Partie Traitement du Langage (TAL)

Exercice 1 (3 points) – Modèle Bag of Words (BoW)

On considère le corpus constitué des deux documents suivants :

D1 : "It was the best of times"

D2 : "It was the age of wisdom"

Q 1.1 Décrire le principe général du modèle Bag of Words (BoW) et les différentes étapes de sa mise en oeuvre.

Q 1.2 Calculer les BoW des documents D1 et D2 avec des unigrammes (mots), en utilisant l'approche "term frequency" (tf) et "term frequency-inverse document frequency" (tf-idf). Quel est l'intérêt de l'approche tf-idf ? Quel pré-traitement peut renforcer ce comportement ?

Q 1.3 Calculer le BoW des documents D1 et D2 avec des bigrammes comme tokens du dictionnaire, pour une normalisation tf. Quel est l'intérêt de l'approche avec bigrammes par rapport aux unigrammes ? Quel est son inconvénient ?

Exercice 2 (5 points) – Latent Semantic Analysis

Q 2.1 Rappeler brièvement les philosophies générales et le fonctionnement des algorithmes PL-SA/LDA et word2vec (philosophie = objectif + hypothèses pour arriver à cet objectif + éléments marquants de l'algorithme). Donner les principaux hypers-paramètres associés aux deux modèles. Quelles sont les sorties associées aux deux modèles.

Q 2.2 Soit la formulation suivante de la décomposition LSA : $D = U\Sigma V^T$. Expliquer l'interprétation de la matrice V comme "champ lexical".

Q 2.3 Expliquer comment effectuer du clustering à partir de la décomposition LSA d'un corpus de documents.

Q 2.4 Quel peut être l'intérêt du LSA dans une chaîne de traitement en NLP ? A quel moment peut-on l'utiliser ?

Exercice 3 (4 points) – Knowledge graph

On considère le texte suivant :

Dr House (House, M.D., puis House) est une série télévisée américaine en 177 épisodes de 43 minutes et répartis sur huit saisons. Elle a été créée par David Shore et sa diffusion s'est déroulée du 16 novembre 2004 au 21 mai 2012 sur le réseau Fox.
(Wikipédia)

Nous souhaitons développer un algorithme de construction de graphe de connaissances. L'idée est de transformer le texte en une série de triplets : { (Dr House, *TYPE*, série TV), (Dr House, *NATIONALITE*, américaine), ... }

Q 3.1 Pourquoi être intéressé par une telle transformation ? (rapidement)

Q 3.2 Quelles sont les problématiques en jeu ? Vous répondrez en terme d'entrées/sorties en ajoutant éventuellement un nom de modèle adapté.

Q 3.3 En imaginant que vous deviez concevoir un tel système, comment procéder ? Donner quelques grandes étapes pour la construction des jeux de données d'apprentissage permettant d'entraîner les modèles attaquant les problématiques mentionnées dans la question précédente.

Exercice 4 (3 points) – Embedding vectoriels

Q 4.1 Décrire le schéma d'entraînement de l'approche "Word2Vec", pour la variantes CBoW.

- Pourquoi dit-on que cette méthode d'entraînement est auto-supervisée ?
- Quel est le problème computationnel lié à la prédiction ? Comment y faire face ?

Q 4.2 A quoi correspondent les propriétés d'analogie quand on étudie l'espace des embeddings ? Donner un exemple.

Exercice 5 (5 points) – Deep learning

Q 5.1 "Word2Vec" est-il un modèle de deep learning ? Si oui expliquer. Sinon, justifier.

Q 5.2 Décrire la méthode de "self-attention" dans les transformers. Quel est son avantage par rapport aux RNNs ?

Q 5.3 Décrire le pré-entraînement du modèle BERT avec les fonctions objectifs Next Sequence Prediction (NSP) et Masked Language Model (MLM).

2 Partie Recherche d'information (TAL)

Exercice 6 (11 points) – Question de cours

Q 6.1 Qu'est-ce que la recherche d'information ? Décrire son processus.

Q 6.2 Commentez ces phrases :

1. Dans un système de recherche booléen, le stemming ne diminue jamais la précision.
2. Dans un système de recherche booléen, le stemming ne diminue jamais le rappel.

3. Le stemming augmente la taille du vocabulaire.
4. Le stemming devrait être invoqué au moment de l'indexation, mais pas pendant le traitement d'une requête.

Q 6.3 Quels sont les avantages et les inconvénients d'un modèle vectoriel ?

Q 6.4 Quel est le principe du modèle probabilistique ? Quelle est sa formule de base ?

Q 6.5 Citez deux avantages de l'application du lissage aux modèles linguistiques.

Q 6.6 Discuter l'impact de l'IA sur les modèles de recherche d'information. Quelles sont les deux principales étapes d'intégration de l'IA en RI ?

Q 6.7 Commenter cette phrase : Dans les algorithmes de type "learning to rank", une estimation parfaite de la pertinence ponctuelle est une condition nécessaire pour retrouver l'ordre de classement parfait.

Q 6.8 Quelles sont les grandes familles de modèles neuronaux qui ont été proposées à ce jour en RI ? Expliquer les grandes lignes et leurs différences. Quels sont les avantages/limites de chacune de ces familles ?

Q 6.9 Expliquer le trade-off précision-rappel pour la recherche d'information.

Q 6.10 Commenter cette phrase : $MRR=0,5$ signifie qu'en moyenne, vous avez 50% de chances de trouver un document pertinent en première position pour une requête donnée.

Q 6.11 Comment évaluer si un **utilisateur** est satisfait des résultats de la recherche ?

Exercice 7 (4 points) – Loi de Zipf

Une des expressions formelles de la loi de Zipf est la suivante :

$$frequency = \frac{\lambda}{rang} (avec \lambda > 0) \quad (1)$$

Q 7.1 Quelle est l'intuition de la loi de Zipf ? A quoi sert-elle ?

Q 7.2 On suppose que le 50^e mot le plus fréquent a une probabilité d'apparition de 0.02 dans une collection de 10 000 mots. Quel est le rang d'un mot qui apparaît 40 fois dans la collection ?

Q 7.3 Si on considère que tous les mots d'une collection ont des fréquences différentes, quel est le nombre total d'occurrences si on considère $\lambda = 36\,000\,000$? Indication : Posez juste la formule, sans faire de calculs si trop compliqué.

Exercice 8 (5 points) – Question ouverte

Q 8.1 Étant donné un annotateur de texte, tel que TagMe (voir Figure 1), montrez comment vous pourriez renforcer la représentation vectorielle TF-IDF afin d'effectuer des comparaisons "sémantiques" entre les documents en utilisant toujours la similarité cosinus.

```
< tagme time = " 5 " lang = " en " >
  < text > us president issues libya ultimatum </ text >
  < annotations >
    < annotation >
      < spot pos = " 20 " len = " 5 " > libya </ spot >
      < title > Libya </ title >
      < id > 17633 </ id >
      < rho > 0.4230 </ rho >
    </ annotation >
    < annotation >
      < spot pos = " 0 " len = " 12 " > us president </ spot >
      < title > President of the United States </ title >
      < id > 24113 </ id >
      < rho > 0.3102 </ rho >
    </ annotation >
    < annotation >
      < spot pos = " 26 " len = " 9 " > ultimatum </ spot >
      < title > Ultimatum </ title >
      < id > 198432 </ id >
      < rho > 0.2139 </ rho >
    </ annotation >
  </ annotations >
</ tagme >
```

FIGURE 1 – Exemple d'annotations fournies par TagMe