



RECHERCHE D'INFORMATION & TRAITEMENT AUTOMATIQUE DU LANGAGE

Cours 3 : Evaluation en Recherche d'Information

2024-25

Laure Soulier / Benjamin Piwowarski



Machine Learning &
Deep Learning for
Information Access

- Quel modèle de RI est le plus efficace ?
- Efficace ? Problème difficile, pas de mesure absolue
 - Critères de qualité d'un système de RI
 - Facilité d'utilisation du système
 - Coût accès/stockage
 - Présentation des résultats
 - Efficacité de la recherche
 - Possibilités de formuler des requêtes riches
- Nombreuses mesures donnent des renseignements partiels sur le comportement du système

EVALUATION CRANFIELD

- Objectif : évaluer la capacité d'un système à retourner des documents pertinents
- De quoi a-t-on besoin ?

Paradigme de Cranfield - première expérimentation "laboratoire" en RI

Evaluation basées sur des collections de test composées de :

- Corpus de documents
- Requêtes
- Jugements de pertinence

- Avantages
 - Peu coûteux
 - Facilite les analyses d'erreurs
 - Répétables
- Inconvénients
 - Jugements de pertinence peuvent être incomplets
 - Quelles hypothèses pour la pertinence ?

- De nombreuses collections de test ont été développés par la communauté scientifique
 - Cranfield fin des années 50
 - TREC (NIST)
 - CLEF
 - NTCIR (Japon et autres langues asiatiques, cross language evaluation)
 - ...

- Ad hoc Test Collections
- Web Test Collections
- Blog Track
- Chemical IR Track
- Clinical Decision Support Track
- Common Core Track
- Confusion Track
- Contextual Suggestion Track
- Interactive Track
- Knowledge Base Acceleration Track
- Legal Track
- Medical Track
- Microblog Track
- Million Query Track
- Novelty Track
- Query Track
- Question Answering Track
- Precision Medicine Track
- Real-time Summarization Track
- Relevance Feedback Track
- Robust Track
- Session Track
- SPAM Track
- Spoken Document Retrieval Track
- Tasks Track
- Temporal Summarization Track
- Terabyte Track
- Web Track

```
<DOC>  
<DOCNO> GPXX-0002 </DOCNO>  
<TITLE> ceci est un titre </TITLE>  
<DATE> 2006-09-04 </DATE>  
<TEXT> ceci est le contenu blablabla blablabla blablabla .</TEXT>  
</DOC>
```

- Souvent les requêtes (mots clés) sont associés à une description plus complète (phrases) du besoin d'information

<top>

<num> Number : 501

<title> deduction and induction in English ?

<desc> Description :

What is the difference between deduction and induction in the process of reasoning ?


<narr> Narrative :

A relevant document will contrast inductive and deductive reasoning.

A document that discusses only one or the other is not relevant.

</top>

- Ensemble de jugements de pertinence pour chaque paire (document, requête)
 - Ces jugements peuvent être binaires ou être donnés sous forme d'un score, typiquement 0, 1, 2, 3, 4, 5
 - Ils sont formulés en fonction du besoin d'information




voorheesTooManyRelevants2022

- Différents types de mesure
 - Rappel/Précision
 - Orientées rang
 - Prise en compte des degrés de pertinence

MÉTRIQUES ORIENTÉES

RAPPEL/PRÉCISION



- Les deux mesures les plus courantes sont :
 - Rappel : est-ce que le système retourne TOUS les documents pertinents ?
 - Précision : est-ce que le système retourne QUE les documents pertinents ?

	Relevant	Non Relevant
Retrieved	True Positive (tp)	False Positive (fp)
not retrieved	False Negative (fn)	True Negative (tn)

- Précision = capacité à ne retrouver QUE des documents pertinents

$$Precision = \frac{tp}{tp + fp} \quad (1)$$

- Rappel = capacité à retrouver TOUS les documents pertinents

$$Rappel = \frac{tp}{tp + fn} \quad (2)$$

- Remarque : accuracy n'est pas une mesure pour la RI

$$Accuracy = \frac{tp + tn}{tp + fp + tn + fn} \quad (3)$$

- Exemple


Rang	Doc	Pertinence
1	324	X
2	654	X
3	454	
4	472	
5	789	X
6	148	X
7	65	
8	32	X
9	78	
10	439	

Exercice

Calculer les mesures de rappel et de précision sachant que la collection inclue 10 documents pertinents

Evaluation d'un système


- Calcul des mesures pour chaque requête
- Moyenne sur l'ensemble des requêtes



- Rappel et précision sont en général antagonistes
 - Sélection de toute la collection $\rightarrow R=1, P=0$
 - Sélection d'un seul document pertinent $\rightarrow R=0, P=1$
- Suivant les utilisations, on peut vouloir favoriser précision (e.g. web) ou rappel (documentalistes)
- Mesure qui combine les deux métriques : F-mesure :

$$F_{\beta} = (1 + \beta^2) \frac{P * R}{\beta^2 P + R} \quad (4)$$

- Les moteurs de recherche renvoient en général des listes ordonnées : l'idéal est de retourner les documents en tête de liste
- Métriques adaptées
 - Précision à k : $P@k(q) = \frac{1}{k} \sum_{i=1}^k R_{d_i,q}$ avec $R_{d_i,q} \in \{0, 1\}$ jugement de pertinence pour le document de rang i renvoyé par le système.
 - Rappel à k : $R@k(q) = \frac{1}{|R|} \sum_{i=1}^k R_{d_i,q}$ avec $R_{d_i,q} \in \{0, 1\}$ jugement de pertinence pour le document de rang i renvoyé par le système.




Rg	RSV(q,d)	Pertinence	Rapel	Precision
1	0.95	1		
2	0.82	0		
3	0.75	0		
4	0.7	1		
5	0.65	1		
6	0.5	0		
7	0.4	0		
8	0.35	1		
9	0.2	0		
10	0.1	0		

Exercice

Tracer la courbe de rappel pour cet ordonnancement.

Rg	RSV(q,d)	Pertinence	Rappel	Precision
1	0.95	1	1/4	1
2	0.82	0	1/4	1/2
3	0.75	0	1/4	1/3
4	0.7	1	1/2	1/2
5	0.65	1	3/4	3/5
6	0.5	0	3/4	1/2
7	0.4	0	3/4	3/7
8	0.35	1	1	1/2
9	0.2	0	1	4/9
10	0.1	0	1	2/5




Précision interpolée

La précision interpolée au point de rappel r_j est égale à la valeur maximale des précisions obtenues aux points de rappel r , tel que $r \geq r_j$

$$P_{interp}(r) = \max_{r' \geq r} P(r') \quad (5)$$

Rg	RSV(q,d)	Pertinence	Rapel	Precision	Pinterp
1	0.95	1	1/4	1	1
2	0.82	0	1/4	1/2	1
3	0.75	0	1/4	1/3	1
4	0.7	1	1/2	1/2	0.6
5	0.65	1	3/4	3/5	0.6
6	0.5	0	3/4	1/2	0.6
7	0.4	0	3/4	3/7	0.6
8	0.35	1	1	1/2	0.5
9	0.2	0	1	4/9	0.5
10	0.1	0	1	2/5	0.5



Précision interpolée (courbe rouge)

La précision interpolée au point de rappel r_j est égale à la valeur maximale des précisions obtenues aux points de rappel r , tel que $r \geq r_j$

$$P_{interp}(r) = \max_{r' \geq r} P(r') \quad (6)$$

avec $r = \{0, 0.1, \dots, 1\}$ ou r issu de la distribution de l'ordonnancement.

→ Estime le pourcentage de documents pertinents qu'un utilisateur observera s'il veut atteindre un rappel au moins égal à r

- Précision moyenne (AvgP) est la moyenne des valeurs de précision des documents pertinents par rapport à la requête :

$$AvgP(q) = \frac{1}{n_+^q} \sum_{k=1}^N R_{d_k, q} \times P@k(q) \quad (7)$$

- On peut également calculer la moyenne arithmétique de la précision interposée prise sur 11 points de rappel (approximation de l'aire sous la courbe précision-rappel)
- Moyenne des précisions moyennes (MAP) est la moyenne des AvgP sur l'ensemble des requêtes :

$$MAP = \frac{1}{|Q|} AvgP(q) \quad (8)$$

MÉTRIQUES ORIENTÉES RANG

- Hypothèse : les documents pertinents doivent être retournés en premier dans la liste
- Moyenne des rangs inverses (Mean reciprocal rank) : moyenne du rang du premier document sur l'ensemble des requêtes

$$MRR = \frac{1}{|Q|} \sum_{q_h \in Q} \frac{1}{Rank_h} \quad (9)$$

- Discounted cumulative gain (DCG)
 - Utilisé dans le cadre de la recherche Web
 - Utilise une information de pertinence graduée (5 niveaux)
 - Mesure le gain d'information apporté par un document en fonction de sa position dans la liste des résultats
 - Pour la RI Web seules les premières informations présentées sont importantes
- Hypothèses
 - Les documents pertinents sont plus utiles quand ils apparaissent à un rang élevé.
 - Les documents très pertinents sont plus utiles que les peu pertinents qui sont plus utiles que les non pertinents.

- Cumulative Gain (CG) - ancêtre de DCG

- CG au rang p

$$CG_p = \sum_{i=1}^p rel_i \quad (10)$$

- où rel_i est la pertinence graduée du document i
- Ne tient pas compte de l'ordre des documents

- Discounted Cumulative Gain (DCG)

- Prise en compte de l'ordre des documents par une fonction décroissante du rang

$$DCG_p = rel_1 + \sum_{i=2}^p \frac{rel_i}{\log_2(i)} \quad (11)$$

- Autres formulations possibles

- Pour moyenner DCG sur un ensemble de requêtes, on calcule une version normalisée NDCG

- On suppose que l'on dispose d'une liste idéale de résultats dont le DCG_p vaut $IDCG_p$

$$nDCG_p = \frac{DCG_p}{IDCG_p} \quad (12)$$

- On moyenne ensuite sur l'ensemble des requêtes
- Il faut bien sûr disposer de la liste idéale... → petites mains du web...

Rang	Doc	Pertinence
1	324	1
2	654	2
3	454	
4	472	
5	789	1
6	148	1
7	65	
8	32	2
9	78	
10	439	

Exercice

Calculer la mesure de NDCG pour l'ordonnancement précédent.

TopicID	X	Y
01	0.70	0.50
02	0.30	0.10
03	0.20	0.00
04	0.60	0.20
05	0.40	0.40
06	0.40	0.30
07	0.00	0.00
08	0.70	0.50
09	0.10	0.30
10	0.30	0.30
11	0.50	0.40
12	0.40	0.40
13	0.00	0.10
14	0.60	0.40
15	0.50	0.20
16	0.30	0.10
17	0.10	0.10
18	0.50	0.60
19	0.20	0.30
20	0.10	0.20

So you used a test collection that has $n=20$ topics to compute nDCG scores for two systems X and Y.

Which system is more effective?

Scores for X, Y: $(x_1, \dots, x_n)$ $(y_1, \dots, y_n)$

Per-topic difference: $d_j = x_j - y_j$

Sample mean of the differences: $\bar{d} = \sum_{j=1}^n d_j / n$

0.0750

Sample variance: $V = \sum_{j=1}^n (d_j - \bar{d})^2 / (n - 1)$

0.0251

Figure 1 – From Tetsuya Sakai, 2005

TopicID	X	Y
01	0.70	0.50
02	0.30	0.10
03	0.20	0.00
04	0.60	0.20
05	0.40	0.40
06	0.40	0.30
07	0.00	0.00
08	0.70	0.50
09	0.10	0.30
10	0.30	0.30
11	0.50	0.40
12	0.40	0.40
13	0.00	0.10
14	0.60	0.40
15	0.50	0.20
16	0.30	0.10
17	0.10	0.10
18	0.50	0.60
19	0.20	0.30
20	0.10	0.20




Figure 2 – From Tetsuya Sakai, 2005


TopicID	X	Y
01	0.70	0.50
02	0.30	0.10
03	0.20	0.00
04	0.60	0.20
05	0.40	0.40
06	0.40	0.30
07	0.00	0.00
08	0.70	0.50
09	0.10	0.30
10	0.30	0.30
11	0.50	0.40
12	0.40	0.40
13	0.00	0.10
14	0.60	0.40
15	0.50	0.20
16	0.30	0.10
17	0.10	0.10
18	0.50	0.60
19	0.20	0.30
20	0.10	0.20

Under the above assumptions,

$d_j = x_j - y_j$ obeys $N(\mu_t, \sigma_t^2)$ where

Population mean of the difference

$$\mu_t = \mu_X - \mu_Y, \quad \sigma_t^2 = \sigma_X^2 + \sigma_Y^2$$



Which system is more effective?

Or, which of these hypotheses is true?

$$\frac{\bar{d} - \mu_t}{\sqrt{\sigma_t^2/n}} \text{ obeys } N(0, 1^2)$$

$$H_0 : \mu_t = 0, \quad H_1 : \mu_t \neq 0$$

If you look at the populations, X and Y are equally effective

If you look at the populations, X and Y are actually different

Figure 3 – From Tetsuya Sakai, 2005

TopicID	X	Y
01	0.70	0.50
02	0.30	0.10
03	0.20	0.00
04	0.60	0.20
05	0.40	0.40
06	0.40	0.30
07	0.00	0.00
08	0.70	0.50
09	0.10	0.30
10	0.30	0.30
11	0.50	0.40
12	0.40	0.40
13	0.00	0.10
14	0.60	0.40
15	0.50	0.20
16	0.30	0.10
17	0.10	0.10
18	0.50	0.60
19	0.20	0.30
20	0.10	0.20

$$H_0 : \mu_t = 0, \quad H_1 : \mu_t \neq 0$$

If H_0 is true, the t statistic obeys a t distribution with $\phi=(n-1)$ degrees of freedom.

Significance level α : areas under curve = a pre-determined probability (e.g. 5%) of observing something very rare




Figure 4 – From Tetsuya Sakai, 2005

- Tests de significativité
 - Vérifier si la différence de performances entre deux systèmes est significative
 - Accepter H_0 (pas de différence entre A et B)
 - Accepter H_1 (A et B sont différents)
 - Plusieurs tests : Student, Wilcoxon, ...
 - Dépend d'un paramètre $\alpha = p(H_1|H_0)$
 - 0.05 $\rightarrow$ 5% de chance de rejeter pour de mauvaises raisons l'hypothèse que $A = B$

🔑 **Correction de Bonferroni** – méthode très simple pour corriger le seuil de significativité lors de comparaisons *multiples* (m systèmes comparés à une baseline) : le seuil est fixé à $\frac{\alpha}{m}$

- Exemple de présentation de résultats

<i>Apprentissage</i>		<i>Prec^S@20</i>		<i>Rappel^S@20</i>		<i>F^S@20</i>	
→		value	%Tx	value	%Tx	value	%Tx
<i>Evaluation</i>							
<i>US2</i>	BM25-RIC	0,016	+185,64***	0,019	+139,62***	0,0177	+166.71***
	Logit-RIC	0,038	+21,66	0,031	+43.50 *	0,033	+31.75 *
→	GS-RIC	0,015	+204,44 ***	0,008	+429.17 ***	0,009	+345.81 ***
	PM-RIC	0,019	+136,62 ***	0,006	+719.35 ***	0,008	+432.37 ***
<i>SansRole</i>	MineRank(q)	0.046		0.045		0.044	
	MineRank(t)	0.040		0.040		0.040	
<i>SansRole</i>	BM25-RIC	0,075	-5,00	0,063	+335,58	0,069	+63,27
	Logit-CIT	0,071	+0,33	0,266	+3,76 ***	0,111	+1,33 ***
→	GS-RIC	0,058	+23,76	0,039	+595,56 *	0,046	+142,58
	PM-RIC	0,092	-22,83	0,078	+254,57	0,084	+32,86
<i>US2</i>	MineRank(q)	0.071		0.276		0.112	
	MineRank(t)	0.064		0.238		0.112	

- Quand l'humain rentre en jeu...
 - Evaluation basée sur les logs utilisateurs
 - User-study

• Evaluation basée sur les logs utilisateurs

RMIT TRAC Interactive Track
Rich Format Data for Z/PRIME and WWW/HC systems
Significant events

Notes: + taken from Z/PRIME and WWW/HC system logs

[S1:3241:WWW/HC]

[Utilisateur:Sujet:Participant]

13:36:07 Session start

Début de la session

Requête

13:36:08 Listing document title (FT944-10102)

13:37:00 Listing document title (FT942-12800)

13:37:00 Listing document title (FT942-6364)

13:37:00 Listing document title (FT911-5368)

13:37:00 Listing document title (FT944-16217)

13:37:00 Listing document title (FT931-6495)

13:37:00 Listing document title (FT944-5094)

13:37:00 Listing document title (FT944-11367)

13:37:00 Listing document title (FT923-9034)

13:37:00 Listing document title (FT944-10109)

13:37:00 Listing document title (FT942-14522)

13:37:01 Listing document title (FT931-16973)

13:37:01 Listing document title (FT931-6871)

13:37:01 Listing document title (FT943-9079)

13:37:01 Listing document title (FT931-9244)

13:37:01 Listing document title (FT941-732)

13:37:01 Listing document title (FT923-3644)

13:37:01 Listing document title (FT911-2904)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)

13:37:01 Listing document title (FT944-15661)



Instant de sélection du document

Document sélectionné

13:37:07 New aspect (0: Banglesh 17.10.94) found in FT944-15661

13:37:32 Listing document title (FT944-15661)

13:37:52 Listing document title (FT923-8101)

13:37:52 Listing document title (FT944-15057)


13:37:52 Listing document title (FT931-5947)

- Evaluation basée sur les logs utilisateurs
 - Permet d'appliquer a posteriori des modèles sur des données utilisateurs



- Avantages
 - Besoin en information généré par un utilisateur réel
 - Automatisation de l'évaluation
- Inconvénients
 - "Artificiel"

- User-study / Living labs



K. Balog, L. Kelly, and A. Schuth. **Head First: Living Labs for Ad-hoc Search Evaluation**. *CIKM'14*

- User-study
 - Utilisateur interagit en temps réel avec le système
- Avantages
 - Evaluation directe du système
 - Au plus proche de l'utilisateur !
- Inconvénients
 - Collecte fastidieuse, coûteuse, ...
 - Difficile d'évaluer toutes les variantes d'un modèle (paramétrage, etc. . .)
 - Evaluation de plusieurs modèles ?

Evaluation des expérimentations en temps réel : Interleaving et A/B tests

Interleaving

- Site provides the **set of candidate items** that can be re-ranked (safety mechanism)
- Experimental ranking is **interleaved** with the production ranking
 - Needs 1-2 order of magnitudes data than A/B testing (also, it is within subject as opposed to between subject design)



A vous de jouer... TD is coming!

