



RITAL @ DAC

Recherche d'Information Neuronale

Benjamin Piwowski

Cours 4

Press ? for help on keyboard shortcuts



Machine Learning &
Deep Learning for
Information Access

LA RI ET L'APPRENTISSAGE

☞ Avec le temps, on a défini beaucoup d'indicateurs pour la pertinence...

Comment les combiner ? ?

☞ Chaque modèle (BM25, PageRank) mesure une certaine forme de pertinence

☞ Comment les combiner ?

ID	Feature Description	Category
1	$\sum_{q_i \in q \cap d} c(q_i, d)$ in body	Q-D
2	$\sum_{q_i \in q \cap d} c(q_i, d)$ in anchor	Q-D
3	$\sum_{q_i \in q \cap d} c(q_i, d)$ in title	Q-D
4	$\sum_{q_i \in q \cap d} c(q_i, d)$ in URL	Q-D
5	$\sum_{q_i \in q \cap d} c(q_i, d)$ in whole document	Q-D
6	$\sum_{q_i \in q} idf(q_i)$ in body	Q
7	$\sum_{q_i \in q} idf(q_i)$ in anchor	Q
8	$\sum_{q_i \in q} idf(q_i)$ in title	Q
9	$\sum_{q_i \in q} idf(q_i)$ in URL	Q
10	$\sum_{q_i \in q} idf(q_i)$ in whole document	Q
11	$\sum_{q_i \in q \cap d} c(q_i, d) \cdot idf(q_i)$ in body	Q-D
12	$\sum_{q_i \in q \cap d} c(q_i, d) \cdot idf(q_i)$ in anchor	Q-D
13	$\sum_{q_i \in q \cap d} c(q_i, d) \cdot idf(q_i)$ in title	Q-D
14	$\sum_{q_i \in q \cap d} c(q_i, d) \cdot idf(q_i)$ in URL	Q-D
15	$\sum_{q_i \in q \cap d} c(q_i, d) \cdot idf(q_i)$ in whole document	Q-D
16	$ d $ of body	D
17	$ d $ of anchor	D
18	$ d $ of title	D
19	$ d $ of URL	D
20	$ d $ of whole document	D

21	BM25 of body	Q-D
22	BM25 of anchor	Q-D
23	BM25 of title	Q-D
24	BM25 of URL	Q-D
25	BM25 of whole document	Q-D
26	LMIR.ABS of body	Q-D
27	LMIR.ABS of anchor	Q-D
28	LMIR.ABS of title	Q-D
29	LMIR.ABS of URL	Q-D
30	LMIR.ABS of whole document	Q-D
31	LMIR.DIR of body	Q-D
32	LMIR.DIR of anchor	Q-D
33	LMIR.DIR of title	Q-D
34	LMIR.DIR of URL	Q-D
35	LMIR.DIR of whole document	Q-D
36	LMIR.JM of body	Q-D
37	LMIR.JM of anchor	Q-D
38	LMIR.JM of title	Q-D
39	LMIR.JM of URL	Q-D
40	LMIR.JM of whole document	Q-D
41	Sitemap based term propagation	Q-D
42	Sitemap based score propagation	Q-D
43	Hyperlink based score propagation: weighted in-link	Q-D
44	Hyperlink based score propagation: weighted out-link	Q-D
45	Hyperlink based score propagation: uniform out-link	Q-D
46	Hyperlink based propagation: weighted in-link	Q-D
47	Hyperlink based feature propagation: weighted out-link	Q-D
48	Hyperlink based feature propagation: uniform out-link	Q-D
49	HITS authority	Q-D
50	HITS hub	Q-D
51	PageRank	D
52	HostRank	D
53	Topical PageRank	Q-D
54	Topical HITS authority	Q-D
55	Topical HITS hub	Q-D

Comment combiner ? ?

- ☞ Chaque modèle (BM25, PageRank) mesure une certaine forme de pertinence
- ☞ Comment les combiner ?
- ☞ Avec l'apparition des modèles paramétrique (Deep Learning)

Comment combiner ? ?

- ☞ Chaque modèle (BM25, PageRank) mesure une certaine forme de pertinence
- ☞ Comment les combiner ?
- ☞ Avec l'apparition des modèles paramétrique (Deep Learning)

☞ Début du Learning To Rank

📖 Fuhr, N. and Buckley, C. 1991. *A Probabilistic Learning Approach for Document Indexing*.

$$\log P(R|q, d) = 1 - \exp(\Phi(q, d) \cdot \theta)$$

☞ Une fonction $\varphi(q, d)$



Premier article

📖 Fuhr, N. and Buckley, C. 1991. *A Probabilistic Learning Approach for Document Indexing*.

$$\varphi(q, d) = \log P(R|q, d) = \sigma(1 + \exp(-\Phi(q, d) \cdot \theta))$$

☞ Un jeu de données en RI

- des questions q
- un ensemble de documents D
- un ensemble de documents pertinents $D_q^+ \subseteq D$
- un ensemble de documents non pertinents $D_q^- \subseteq D$

⚠ On verra plus tard comment sont définis ces ensembles

☞ Supposons pour l'instant que nous avons ces données

φ est coûteux en temps de calcul ?

φ a été appris... mais c'est lent !

Comment peut-on faire pour aller plus vite ?

φ est coûteux en temps de calcul ?

φ a été appris... mais c'est lent !

Comment peut-on faire pour aller plus vite ?

💡 Ordonnancement en deux étapes (Two-Stage Ranking)

1. On cherche le top- K (ex. $K = 1000$) avec BM25 ou un autre modèle **rapide**
2. On ré-ordonne les K document avec φ

Comment apprendre un modèle qui maximise une métrique de RI? ?

- ☞ Pas possible en général
- ☞ On utilise des relaxations du problème

Comment apprendre un modèle qui maximise une métrique de RI? ?

- ☞ Pas possible en général
- ☞ On utilise des relaxations du problème

☞ Trois façons d'aborder le problème

Pointwise

Estimer une note ou un label (pertinent ou non) pour un seul document
Les documents sont traités **indépendamment** (régression, classification)

Pairwise

Estimer une préférence d'ordre entre des **paires** de documents
Documents dépendants au sein de la paire, paires indépendantes

Listwise

Estimer l'ordre total dans une **liste** de documents
Les scores des documents dépendent les uns des autres

📖 *Liu, T.-Y. 2011. Learning to Rank for Information Retrieval.*

POINTWISE

PAIRWISE

LISTWISE

Non spécifique à une métrique

Spécifique à une métrique

📖 Liu, T.-Y. 2011. *Learning to Rank for Information Retrieval*.

POINTWISE

- **Régression : LSRF**

📖 Fuhr, N. and Buckley, C. 1991. *A Probabilistic Learning Approach for Document Indexing*.

- **Classification : McRank**

📖 Li, P. et al. 2007. *McRank: Learning to Rank Using Multiple Classification and Gradient Boosting*. *Advances in Neural Information Processing Systems*.

- **Régression ordinale : Pranking**

📖 Crammer, K. and Singer, Y. 2001. *Pranking with Ranking*. *Advances in Neural Information Processing Systems*.

PAIRWISE

LISTWISE

Non spécifique à une métrique

Spécifique à une métrique

📖 Liu, T.-Y. 2011. *Learning to Rank for Information Retrieval*.

POINTWISE

PAIRWISE

- RankSVM

📖 Joachims, T. 2002. *Optimizing Search Engines Using Clickthrough Data*. *Proceedings of the Eighth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*.

- RankBoost

📖 Freund, Y. et al. 2003. *An Efficient Boosting Algorithm for Combining Preferences*.

- RankNet

📖 Burges, C. et al. 2005. *Learning to Rank Using Gradient Descent*. *Proceedings of the 22nd International Conference on Machine Learning*.

- LambdaRank

📖 Burges, C.J.C. et al. 2007. *Learning to Rank with Nonsmooth Cost Functions*.

LISTWISE

Non spécifique à une métrique

Spécifique à une métrique

📖 Liu, T.-Y. 2011. *Learning to Rank for Information Retrieval*.

POINTWISE

PAIRWISE

LISTWISE

Non spécifique à une métrique

- ListNet

📖 Cao, Z. et al. 2007. *Learning to Rank: From Pairwise Approach to Listwise Approach*. *Proceedings of the 24th International Conference on Machine Learning*.

- ListMLE (2008), BoltzRank (2009), ...

Spécifique à une métrique

📖 Liu, T.-Y. 2011. *Learning to Rank for Information Retrieval*.

POINTWISE

PAIRWISE

LISTWISE

Non spécifique à une métrique

Spécifique à une métrique

- AdaRank

📖 2007. *AdaRank: A Boosting Algorithm for Information Retrieval*.

- SoftRank

📖 Taylor, M. et al. 2008. *SoftRank: Optimizing Non-Smooth Rank Metrics*. WSDM.

- LambdaMART

📖 Wu, Q. et al. 2010. *Adapting Boosting for Information Retrieval Measures*.



PCE

$$\Delta_{PCE}(p_{\theta}(q, d, y)) = y \log p_{\theta}(R|q, d) + (1 - y) \log (1 - p_{\theta}(R|q, d))$$

- ☞ Facile à mettre en place
- ☞ Peut être instable lors de l'apprentissage

▼ Max-Margin

max-margin loss

$$\Delta(f_{\theta}(q, d_+), f_{\theta}(q, d_-)) = \max \{0, 1 - (f_{\theta}(q, d_+) - f_{\theta}(q, d_-))\}$$

Le minimum 0 est atteint si

$$f_{\theta}(q, d_+) > f_{\theta}(q, d_-) + 1$$

InfoNCE

Coût défini pour une liste de documents $\approx$ mesure de RI

La plus utilisée actuellement en LETOR / RI

$$\Delta(f, q, \tilde{D}) = \sum_{d_+ \in \tilde{D} \cap D_q^+} R(q, d_j) \log \frac{\exp(f_\theta(q, d_+))}{\sum_{d \in \tilde{D}} \exp(f_\theta(q, d))}$$

où R est 1 si d_j est pertinent pour q (0 sinon)

☞ Très utilisé en pairwise ($\tilde{D}$ avec deux documents) pour le ré-ordonnancement

☞ Pour l'ordonnancement, on utilise l'ensemble / un sous-ensemble des documents du batch

Enjeu = il faut trouver le meilleur $\tilde{D}$

📖 Lindgren, E. et al. 2021. *Efficient Training of Retrieval Models using Negative Cache*.

☞ Essaie de trouver l'ensemble $\tilde{D}$ tel que le gradient soit le plus proche possible du cas où $\tilde{D} = D$

📖 Taylor, M. et al. 2008. *SoftRank: Optimizing Non-Smooth Rank Metrics*. WSDM.

🔧 On peut approximer la mesure nDCG pour SoftNDCG

$$\mathbb{E} [nDCG] \approx \frac{1}{|Q|} \sum_{q \in Q} \sum_{d \in \mathcal{D}} \frac{g(d|q)}{CG_{\max}(q)} \sum_{r \geq 1} d(r) p(\mathbf{K} = r | \mathbf{q}, \mathbf{d})$$

où $\mathbf{K}$ est la variable aléatoire donnant le rang du document pour la question, d le discount de nDCG et $g(d|q)$ le gain de nDCG pour le document d et la question q .

📖 Taylor, M. et al. 2008. *SoftRank: Optimizing Non-Smooth Rank Metrics*. WSDM.

🔧 On peut approximer la mesure nDCG pour SoftNDCG

$$\mathbb{E}[nDCG] \approx \frac{1}{|Q|} \sum_{q \in Q} \sum_{d \in \mathcal{D}} \frac{g(d|q)}{CG_{\max}(q)} \sum_{r \geq 1} d(r) p(\mathbf{K} = r | \mathbf{q}, \mathbf{d})$$

où $\mathbf{K}$ est la variable aléatoire donnant le rang du document pour la question, d le discount de nDCG et $g(d|q)$ le gain de nDCG pour le document d et la question q .

Deux questions ?

(1) Pourquoi $\approx$? (2) Comment estimer $p(\mathbf{K} = k | \mathbf{q}, \mathbf{d})$?

📖 Taylor, M. et al. 2008. *SoftRank: Optimizing Non-Smooth Rank Metrics*. WSDM.

🔧 On peut approximer la mesure nDCG pour SoftNDCG

$$\mathbb{E} [nDCG] \approx \frac{1}{|Q|} \sum_{q \in Q} \sum_{d \in \mathcal{D}} \frac{g(d|q)}{CG_{\max}(q)} \sum_{r \geq 1} d(r) p(\mathbf{K} = r | \mathbf{q}, \mathbf{d})$$

où $\mathbf{K}$ est la variable aléatoire donnant le rang du document pour la question, d le discount de nDCG et $g(d|q)$ le gain de nDCG pour le document d et la question q .

Deux questions ?

(1) Pourquoi $\approx$? (2) Comment estimer $p(\mathbf{K} = k | \mathbf{q}, \mathbf{d})$?



Distribution de score normale

📖 Taylor, M. et al. 2008. *SoftRank: Optimizing Non-Smooth Rank Metrics*. WSDM.

🔧 On peut approximer la mesure nDCG pour SoftNDCG

$$\mathbb{E}[nDCG] \approx \frac{1}{|Q|} \sum_{q \in Q} \sum_{d \in \mathcal{D}} \frac{g(d|q)}{CG_{\max}(q)} \sum_{r \geq 1} d(r) p(\mathbf{K} = r | \mathbf{q}, \mathbf{d})$$

où $\mathbf{K}$ est la variable aléatoire donnant le rang du document pour la question, d le discount de nDCG et $g(d|q)$ le gain de nDCG pour le document d et la question q .

Deux questions ?

(1) Pourquoi $\approx$? (2) Comment estimer $p(\mathbf{K} = k | \mathbf{q}, \mathbf{d})$?

💡 Distribution de score normale

On suppose que $S_i \sim \mathcal{N}(\mu_i, \sigma^2)$ où μ_i est le score donné par le système de RI
Soit π_{ij} la probabilité que d_i soit avant d_j :

$$\pi_{ij} = P(S_i > S_j) = P(S_i - S_j > 0)$$

ce qui correspond à la fonction cumulative de distribution normale, facilement dérivable.

LA RI ET L'APPRENTISSAGE ► D'OÙ VIENNENT LES DONNÉES ?

SOURCES DE POSITIFS (D_q^+)

Jugements humains

Annotation manuelle (coûteux, peu de données, mais fiable)

Clics utilisateurs

Signal implicite (beaucoup de données, mais bruité)

Ancres / liens

Le texte d'ancre sert de "requête" pour le document cible

LA RI ET L'APPRENTISSAGE ► D'OÙ VIENNENT LES DONNÉES ?

SOURCES DE POSITIFS (D_q^+)

Jugements humains

Annotation manuelle (coûteux, peu de données, mais fiable)

Clics utilisateurs

Signal implicite (beaucoup de données, mais bruité)

Ancres / liens

Le texte d'ancre sert de "requête" pour le document cible

Mais où trouver D_q^- ? ?

Les jeux de données à grande échelle (ex. MS MARCO) ne fournissent que des **positifs** (souvent un seul par requête)

Les négatifs ne sont **pas annotés** — il faut les construire

LA RI ET L'APPRENTISSAGE ► D'OÙ VIENNENT LES DONNÉES ?

SOURCES DE POSITIFS (D_q^+)

Jugements humains

Annotation manuelle (coûteux, peu de données, mais fiable)

Clics utilisateurs

Signal implicite (beaucoup de données, mais bruité)

Ancres / liens

Le texte d'ancre sert de "requête" pour le document cible

Mais où trouver D_q^- ? ?

Les jeux de données à grande échelle (ex. MS MARCO) ne fournissent que des **positifs** (souvent un seul par requête)

Les négatifs ne sont **pas annotés** — il faut les construire

SOURCES DE NÉGATIFS (D_q^-)

🔍 Les documents non annotés sont supposés non pertinents

⚠️ Mais lesquels choisir parmi des millions ? → voir slides suivantes

💡 Beaucoup de données mais plus bruitées

Actions des utilisateurs

- Reformulation
- Clics
- ...

💡 Peu de données supervisées mais des modèles

On a des questions - logs ou générées (ex. ancrés)

... mais pas d'indication de pertinence

🔧 Utilisons les "vieux" modèles !

📖 Dehghani, M. et al. 2017. *Neural Ranking Models with Weak Supervision*.

⚠ Négatifs aléatoires = trop faciles

Si on échantillonne des documents au hasard, le modèle apprend vite à les distinguer
Il n'apprend pas à distinguer les documents **presque** pertinents des vrais pertinents

D'OÙ VIENNENT LES NÉGATIFS ?

Ré-ordonnancement

On utilise les documents retournés par BM25 (ou autre) comme candidats

Ordonnancement complet

On échantillonne dans l'ensemble des documents D en utilisant d'autres modèles de RI

📖 Hofstätter, S. et al. 2021. *Improving Efficient Neural Ranking Models with Cross-Architecture Knowledge Distillation*. Technical Report
#arXiv:2010.02666.

STRATÉGIES DE NÉGATIFS DIFFICILES (HARD NEGATIVES)

In-batch negatives

Les documents positifs des autres requêtes du mini-batch servent de négatifs

ANCE (Approximate Nearest Neighbor)

On utilise le modèle lui-même (mis à jour périodiquement) pour trouver les négatifs les plus difficiles

📖 Xiong, L. et al. 2020. *Approximate Nearest Neighbor Negative Contrastive Learning for Dense Text Retrieval*.

⚠ Le choix des négatifs a un impact très fort sur la qualité du modèle final

⚠ Documents pertinents mais estimés non pertinents

Collection avec peu de labels (clics, jugements humains très peu nombreux, ...)

☞ On peut traiter le problème de deux façons :

1. Essayer d'estimer si c'est un faux négatif avec un autre modèle

📖 *RocketQA: An Optimized Training Approach to Dense Passage Retrieval for Open-Domain Question Answering.*

2. Utiliser des techniques de distillation

☞ On minimise la distance entre les prédictions des modèles

📖 *Gao, L. et al. 2020. Understanding BERT Rankers Under Distillation.*

Une autre technique d'apprentissage est basée sur la distillation



Idée originale = ré-entraîner un modèle (student-teacher) marche bien

 Furlanello, T. et al. 2018. *Born-Again Neural Networks*.

En RI, deux raisons pour lesquelles la distillation est essentielle

1. Les cross-encoder BERT sont faciles à entraîner... mais **très** gourmands en ressources
2. Il y a beaucoup de faux négatifs

MARGIN-MSE

On compare les marges entre les prédictions du professeur et de l'élève

$$\text{Margin-MSE}(t^+, t^-, s^+, s^-) = |(t^+ - t^-) - (s^+ - s^-)|^2$$

où t^+, t^- sont les scores du professeur, s^+, s^- ceux de l'élève

DIVERGENCE KL

On fait correspondre la distribution complète des scores

$$\mathcal{L} = \text{KL}(\text{softmax}(t/\tau) \parallel \text{softmax}(s/\tau))$$

avec la température τ pour adoucir les distributions

- 🔑 Attention aux échantillons (ordonnancement ou ré-ordonnancement ?)
 - 🔑 Possibilité d'utilisation d'une supervision faible (interaction utilisateur et/ou modèles classiques)
 - 🔑 La distillation est **très efficace**
 - 🔑 Attention au problème du transfert
- 📖 Thakur, N. et al. 2021. *BEIR: A Heterogenous Benchmark for Zero-shot Evaluation of Information Retrieval Models*.
- 📖 Zhan, J. et al. 2022. *Evaluating Extrapolation Performance of Dense Retrieval*.

► PLAN DU COURS

- Comment apprendre les paramètres ?
- **Réseaux de neurones en RI**
 - Modèles denses (représentation)
 - Modèles parcimonieux (représentation)
 - Modèles d'interaction (interaction faible et forte)
- Approches génératives

Query: united states president

The **President** of the **United States** of America (POTUS) is the elected head of state and head of government of the **United States**. The **president** leads the executive branch of the federal government and is the commander in chief of the **United States Armed Forces**. Barack Hussein Obama II (born August 4, 1961) is an American politician who is the 44th and current **President** of the United States. He is the first African American to hold the office and the first president born outside the continental United States.

The President of the **United States** of America (POTUS) is the elected head of state and head of government of the **United States**. The **president** leads the executive branch of the federal government and is the commander in chief of the **United States Armed Forces**. **Barack Hussein Obama II** (born August 4, 1961) is an American politician who is the 44th and current President of the **United States**. He is the first African American to hold the office and the first president born outside the continental United States.

Traditional IR models estimate relevance based on **lexical matches** of query terms in document

Representation learning based models garner evidence of relevance from all document terms based on **semantic matches** with query

Both **lexical** and **semantic** matching are important and can be modelled with **neural networks**

Les modèles **traditionnels** estiment la pertinence via la correspondance lexicale des termes de la requête dans le document

Les modèles à base de **représentations apprises** exploitent la correspondance sémantique de tous les termes du document avec la requête

☞ Les deux types de correspondance sont importants et peuvent être modélisés par des **réseaux de neurones**

⚠ Représentations indépendantes de la tâche

Les représentations de documents/requêtes (Word2Vec, GloVe, ...) sont apprises **indépendamment** de la tâche de recherche

Adaptées à l'appariement sémantique, mais pas spécifiquement à la **pertinence**

💡 Guider la représentation par la tâche

Apprendre les représentations **et** la fonction de score conjointement

Objectif = ordonnancement (apprendre à ordonner)

DEUX GRANDES FAMILLES


Modèles denses / siamois

On apprend la représentation de la requête et du document en même temps que la fonction de score


Modèles basés sur l'interaction

On construit une matrice d'interaction terme-à-terme, donnée en entrée au réseau


► COMPARAISON RAPIDE



Modèle de représentation
(dense ou parcimonieux)




Interaction tardive




Cross-encodeur


► COMPARAISON RAPIDE



Modèle de représentation
(dense ou parcimonieux)



Interaction tardive



Cross-encodeur


☒ Rapide

☐ Moins robuste

☒ Dense : ANCE, TAS-Balanced, ...

☒ Parcimonieux : SPLADE, DocT5, ...

► COMPARAISON RAPIDE




Modèle de représentation
(dense ou parcimonieux)

⊕ Rapide

⊖ Moins robuste

☞ Dense : ANCE, TAS-Balanced, ...

☞ Parcimonieux : SPLADE, DocT5, ...




Interaction tardive

⊕ Plus robuste


⊖ Un peu plus lent,
stockage important

☞ ColBERT,
ColBERTv2/PLAID




Cross-encodeur

► COMPARAISON RAPIDE




Modèle de représentation
(dense ou parcimonieux)

- ☒ Rapide
- ☐ Moins robuste
- ☞ Dense : ANCE, TAS-Balanced, ...
- ☞ Parcimonieux : SPLADE, DocT5, ...



Interaction tardive


- ☒ Plus robuste
- ☐ Un peu plus lent, stockage important
- ☞ ColBERT, ColBERTv2/PLAID



Cross-encodeur


- ☒ Meilleures performances
- ☐ Très lent (ré-ordonnancement uniquement)
- ☞ monoBERT

► COMPARAISON RAPIDE




Modèle de représentation
(dense ou parcimonieux)

- + Rapide
- Moins robuste
- ☞ Dense : ANCE, TAS-Balanced, ...
- ☞ Parcimonieux : SPLADE, DocT5, ...



Interaction tardive

- + Plus robuste
- Un peu plus lent, stockage important
- ☞ ColBERT, ColBERTv2/PLAID



Cross-encodeur

- + Meilleures performances
- Très lent (ré-ordonnancement uniquement)
- ☞ monoBERT

AVANT LES TRANSFORMERS...

AVANT LES TRANSFORMERS... ► MODÈLES NEURONAUX PRÉ-BERT

- ☞ Avant BERT (2018), de nombreux modèles neuronaux ont été proposés pour la RI

MODÈLES DE REPRÉSENTATION

- ☞ Word2Vec, GloVe, FastText → représentations denses des mots
- ☞ Composition : moyenne (pondérée) des embeddings, ou encodeur-décodeur

MODÈLES D'INTERACTION

- ☞ Matrice d'interaction terme-à-terme + agrégation (convolution, histogrammes, noyaux)
- ☞ DRMM (2016), KNRM (2017), DUET (2017), ...

MODÈLES PARCIMONIEUX

- ☞ SNRM (2018) : premiers essais de représentations parcimonieuses apprises

AVANT LES TRANSFORMERS... ► DESM: DUAL EMBEDDING SPACE MODEL (2016)

📖 Mitra, B. et al. 2016. *A Dual Embedding Space Model for Document Ranking*.

🔧 Word2Vec apprend **deux** représentations par mot : vecteur d'entrée (IN) et vecteur de sortie (OUT)

- Comparer des mots dans le **même** espace (IN-IN ou OUT-OUT) capture la **similarité sémantique** (ex. "voiture" $\approx$ "automobile")
- Comparer des mots entre les **deux** espaces (IN-OUT) capture la **co-occurrence thématique** (ex. "moteur" apparaît dans le contexte de "voiture")

REPRÉSENTATION ET SCORE

🔧 Le document est représenté par la moyenne (normalisée) des vecteurs **OUT** de ses mots :

$$\vec{v}_{d,OUT} = \frac{1}{|d|} \sum_{t_d \in d} \frac{\vec{v}_{t_d,OUT}}{\|\vec{v}_{t_d,OUT}\|}$$

🔧 Le score compare **chaque mot** de la requête (espace IN) au document (espace OUT) — interaction tardive (comme ColBERT) :

$$RSV(q, d) = \frac{1}{|q|} \sum_{t_q \in q} \cos(\vec{v}_{t_q,IN}, \vec{v}_{d,OUT})$$

AVANT LES TRANSFORMERS... ► ET SI ON PRENAIT UN PEU DE REcul...

Model \ Data Set	Robust04		GOV2 _{MQ2007}		Sogou-Log	
	MAP	P@20	MAP	P@10	NDCG@1	NDCG@10
BM25[46] (1994) ^{2,4}	0.255	0.370	0.450	0.366	0.142	0.287
QL[116] (1998) ^{1,4}	0.253	0.369	\	\	0.126	0.282
RM3[117](2001) ⁴	0.287	0.377	\	\	\	\
RankSVM[118] (2002) ²	\	\	0.464	0.381	0.146	0.309
LambdaMart[97] (2010) ^{2,4}	\	\	0.468	0.384	\	\
DSSM[13] (2013) ^{1,2} _{S/R/G}	0.095	0.171	0.409	0.352	\	\
CDSSM[47] (2014) ^{1,2} _{S/R/G}	0.067	0.125	0.364	0.291	0.144	0.333
ARC-I[17] (2014) ^{1,2} _{S/R/G}	0.041	0.065	0.417	0.364	\	\
ARC-II[17] (2014) ^{1,2} _{S/I/G}	0.067	0.128	0.421	0.366	\	\
MP[18] (2016) ^{1,2} _{S/I/G}	0.189	0.290	0.434	0.371	0.218	0.380
Match-SRNN[69] (2016) ² _{S/H/G}	\	\	0.456	0.384	\	\
DRMM[21] (2016) ^{1,2,4} _{A/I/G}	0.279	0.382	0.467	0.388	0.137	0.315
Duet[23] (2017) ³ _{A/H/G}	\	\	0.474	0.398	\	\
DeepRank[33] (2017) ² _{A/I/G}	\	\	0.497	0.412	\	\
K-NRM[85] (2017) ⁴ _{A/I/G}	\	\	\	\	0.264	0.428
SNRM[28] (2018) ⁵ _{S/R/G}	0.286	0.377	\	\	\	\
SNRM+PRF[28] (2018) ⁵ _{S/R/G}	0.297	0.395	\	\	\	\
CONV-KNRM[84] (2018) ⁴ _{A/I/M}	\	\	\	\	0.336	0.481
HiNT[34] (2018) ³ _{A/I/G}	\	\	0.502	0.418	\	\

☞ BM25 fonctionnait **bien** face aux modèles neuronaux pré-transformers !

☞ Plus de données d'entraînement = c'est mieux

☞ La plupart des évaluations portaient sur des textes courts (titres)

⚠ Il a fallu attendre les transformers (BERT, 2018) pour dépasser significativement BM25

MODÈLES DENSES

💡 Espace sémantique

Tout texte t est représenté par $f_{\theta}(t) \in \mathbb{R}^n$

- Modèle symétrique $s(t_1, t_2) = g(f_{\theta}(t_1), f_{\theta}(t_2))$
- Modèle asymétrique $s(t_1, t_2) = g(f_{\theta}^{(l)}(t_1), f_{\theta}^{(r)}(t_2))$

⚠ Problème

- Le texte est une séquence (de mots, de caractères)
- Les réseaux de neurones traitent des entrées de taille fixe
- Comment faire ???

Comment faire ? ?

- Un bon vieux Latent Semantic Analysis (= SVD)...
- Réseaux de neurones récurrents (mais pas vraiment utilisé)
 - ☞ On utilise s_T et/ou $s_1^{(r)}$
- Réseaux Convolutionnels
 - ☞ Représentation de taille fixe après un pooling
- Transformers
 - ☞ On utilise le [CLS] ou la moyenne

🔑 Ils sont tous basés sur le même modèle

Un bon vieux modèle vectoriel basé sur un modèle transformer :

$$\hat{q} = BERT_{\text{CLS}}([CLS] q_1 \dots q_n [SEP])$$

et

$$\hat{d} = BERT_{\text{CLS}}([CLS] d_1 \dots d_m [SEP])$$

Le score est donné par

$$s(q, d) = \hat{q} \cdot \hat{d}$$

MODÈLES DENSES ► APPRENTISSAGE D'UN MODÈLE DENSE : TAS-BALANCED (2021)

📖 Hofstätter, S. et al. 2021. Efficiently Teaching an Effective Dense Retriever with Balanced Topic Aware Sampling.




Figure 2: Comparison of batch sampling strategies. Each strategy has access to a pool of (clustered) queries; where each query has a set of relevant and non-relevant passage pairs with BERT_{CAT} score margins.

- 🔑 Utilisation de la représentation de [CLS] pour le document / la question
- 🔑 Utilisation de la distillation (voir plus loin)
- 🔑 Échantillonnage des questions intéressantes (mini-batch, voir plus loin)

Un meilleur pré-entraînement permet d'améliorer les performances

📖 Gao, L. and Callan, J. 2021. *Condenser: a Pre-training Architecture for Dense Retrieval*.

☞ On force le CLS à encoder de l'information sémantique




Figure 1: Condenser: Shown are 2 early and 2 late backbone layers. Our experiments each have 6 layers. Condenser Head is dropped during fine-tuning.

☞ On utilise des bouts de documents comme des questions

then form a training batch of coCondenser. Write a span s_{ij} 's corresponding *late* CLS representation h_{ij} , its corpus-aware contrastive loss is defined over the batch,

$$\mathcal{L}_{ij}^{co} = -\log \frac{\exp(\langle h_{i1}, h_{i2} \rangle)}{\sum_{k=1}^n \sum_{l=1}^2 \mathbb{I}_{ij \neq kl} \exp(\langle h_{ij}, h_{kl} \rangle)} \quad (6)$$

Familiar readers may recognize this as the contrastive loss from SimCLR (Chen et al., 2020), for which we use random span sampling as augmentation. Others may see a connection to noise contrastive estimation (NCE). Here we provide an NCE narrative. Following the spirit of the distribu-

⚠ Recherches dans un espace dense

Le calcul de produit scalaires est coûteux... Comment peut-on accélérer les recherches ?

⚠ Recherches dans un espace dense

Le calcul de produit scalaires est coûteux... Comment peut-on accélérer les recherches ?

CLUSTERING: CELL-PROBE METHODS (IVF, HNSW)

☞ On groupe les documents dans des clusters (éventuellement hiérarchique)

☞ enjeu = trouver le plus petit ensemble de clusters qui couvrent les "bons" documents

PRODUCT QUANTIZATION (PQ)

☞ Nous découpons le vecteur en k et utilisons un dictionnaire

$$x = \hat{d}_{\hat{x}_1}^{(1)} \oplus \dots \oplus \hat{d}_{\hat{x}_k}^{(k)}$$

où d est commun à l'ensemble des vecteurs et $\hat{x}_i$ est un entier

☞ Le produit scalaire entre x et y est approximé par

$$\sum_{i=1}^k d_{\hat{x}_i}^{(i)} \cdot d_{\hat{y}_i}^{(i)}$$

📖 Malkov, Y.A. and Yashunin, D.A. 2018. *Efficient and robust approximate nearest neighbor search using Hierarchical Navigable Small World graphs.*

📖 Jegou, H. et al. 2011. *Product quantization for nearest neighbor search.*

Possibilité d'apprendre en indexant (Product Quantization)

📖 Zhan, J. et al. 2021. *Learning Discrete Representations via Constrained Clustering for Effective and Efficient Dense Retrieval.*

MODÈLES DENSES ► CONCLUSION

⊕ Représentation compacte et sémantique

⊖ Perte de précision

☞ On combine avec un modèle standard (ex. BM25)

☞ ... ou procédure d'apprentissage complexe

⊖ Adaptation à d'autres domaines moins performante que d'autres modèles (interaction/parcimonieux)

⊖ Temps de recherche long

☞ Utilisation de bibliothèques permettant d'indexer des vecteurs ([FAISS](#)) et en particulier les consignes pour le choix du type d'index

☞ Pas d'études du coût espace/temps à l'heure actuelle

MODÈLES PARCIMONIEUX



Les indices c'est efficace !

- 🔑 Pourquoi ne pas utiliser des représentations parcimonieuses ?
- 🔑 On peut ensuite ordonner **l'ensemble des documents**

- Idée = prédire le poids d'un terme
- On se base sur la représentation contextualisée + modèle (linéaire)

Table 5: Visualization of DeepCT-Index passage term weights. Red shades reflect the normalized term weights – the percentage of total passage term weights applied to the term. White indicates zero weight. Query terms are bold.

	Percentage of weights a term takes in the passage: 010%20%30%40%>50%
Query	who is susan boyle
On-Topic	Amateur vocalist Susan Boyle became an overnight sensation after appearing on the first round of 2009’s popular U.K. reality show Britain’s Got Talent.
Off-Topic	Best Answer: a troll is generally someone who tries to get attention by posting things everyone will disagree, like going to a susan boyle fan page and writing susan boyle is ugly on the wall. they are usually 14-16 year olds who crave attention.
Query	what values do zoos serve
On-Topic	Zoos serve several purposes depending on who you ask. 1) Park/Garden: Some zoos are similar to a botanical garden or city park. They give people living in crowded, noisy cities a place to walk through a beautiful, well maintained outdoor area. The animal exhibits create interesting scenery and make for a fun excursion.
Off-topic	There are NO purebred Bengal tigers in the U.S. The only purebred tigers in the U.S. are in AZA zoos and include 133 Amur (AKA Siberian), 73 Sumatran and 50 Malayan tigers in the Species Survival Plan. All other U.S. captive tigers are inbred and cross bred and do not serve any conservation value .
Query	do atoms make up dna
On-Topic	DNA only has 5 different atoms - carbon, hydrogen, oxygen, nitrogen and phosphorous. According to one estimation, there are about 204 billion atoms in each DNA .
Off-Topic	Genomics in Theory and Practice. What is Genomics . Genomics is a study of the genomes of organisms. It main task is to determine the entire sequence of DNA or the composition of the atoms that make up the DNA and the chemical bonds between the DNA atoms .

Dai, Z. and Callan, J. 2019. Context-Aware Sentence/Passage Term Importance Estimation For First Stage Retrieval.

☞ Le poids d'un terme est estimé par une transformation linéaire (poids w et biais b) de la représentation contextuelle $x^{(t)}$ donnée par BERT (pour la question q et le document d)

$$y_{t,d} = x^{(t)} \cdot w_1 + b_1$$

$$y_{t,q} = x^{(t)} \cdot w_2 + b_2$$

Ensuite $rsv(q, d) = \sum_{t \in q} y_{t,q} y_{t,d}$

☞ Les valeurs cible y sont données par des estimations de pertinence sur un jeu de données d'entraînement

MODÈLES PARCIMONIEUX ► DEEPCT (DÉTAILS)

☞ Le poids d'un terme est estimé par une transformation linéaire (poids w et biais b) de la représentation contextuelle $x^{(t)}$ donnée par BERT (pour la question q et le document d)

$$y_{t,d} = x^{(t)} \cdot w_1 + b_1$$


$$y_{t,q} = x^{(t)} \cdot w_2 + b_2$$

Ensuite $rsv(q, d) = \sum_{t \in q} y_{t,q} y_{t,d}$


☞ Les valeurs cible y sont données par des estimations de pertinence sur un jeu de données d'entraînement

☐ Les mots absents ne sont pas ajoutés → besoin d'**expansion**

🔑 Idée = **expansion** : générer les questions auxquelles le document répond



🔧 Idée = **expansion** : générer les questions auxquelles le document répond



❌ Expansion sans pondération apprise → les poids des termes ne sont pas optimisés

💡 Combiner expansion et pondération

DocT5 (expansion du vocabulaire) + DeepCT (poids des termes)

Table 2: Effectiveness metrics and mean response time (MRT, in ms) for first-stage methods, on MSMARCO Dev Queries, TREC 2019 queries, and TREC 2020 queries. The symbol ∇ denotes a significant difference viz. DeepImpact

Strategy	NDCG@10	MRR@10	MAP	MRT
MSMARCO Dev Queries				
BM25	0.235 [∇]	0.188 [∇]	0.196 [∇]	13.24
DeepCT	0.298 [∇]	0.244 [∇]	0.252 [∇]	10.91
DocT5Query	0.338 [∇]	0.278 [∇]	0.286 [∇]	12.62
DeepImpact	0.385	0.326	0.332	58.64
TREC 2019				
BM25	0.497 [∇]	0.683	0.290 [∇]	10.27
DeepCT	0.578 [∇]	0.714	0.329 [∇]	11.02
DocT5Query	0.648	0.799	0.405	11.76
DeepImpact	0.695	0.863	0.456	51.23
TREC 2020				
BM25	0.483 [∇]	0.659 [∇]	0.286 [∇]	14.67
DeepCT	0.550 [∇]	0.705	0.349 [∇]	12.00
DocT5Query	0.619	0.742	0.408	15.51
DeepImpact	0.651	0.820	0.426	58.00

Table 3: Effectiveness metrics and mean response time (MRT, in ms) using several re-ranking techniques on MSMARCO Dev Queries, TREC 2019 queries, and TREC 2020 queries. ∇ denotes a significant difference viz. ColBERT E2E

Strategy	NDCG@10	MRR@10	MRT
MSMARCO Dev Queries			
DeepImpact + EPIC	0.367 [∇]	0.303 [∇]	194.64
DeepImpact + ColBERT	0.425	0.362	81.00
ColBERT E2E	0.424	0.361	380.97
TREC 2019			
DeepImpact + EPIC	0.711	0.880	191.23
DeepImpact + ColBERT	0.722	0.826	73.29
ColBERT E2E	0.694	0.826	370.98
TREC 2020			
DeepImpact + EPIC	0.646	0.773	196.00
DeepImpact + ColBERT	0.691	0.781	79.84
ColBERT E2E	0.676	0.776	364.82

📖 Mallia, A. et al. 2021. Learning Passage Impacts for Inverted Indexes.

💡 Combiner expansion et pondération

DocT5 (expansion du vocabulaire) + DeepCT (poids des termes)

Table 2: Effectiveness metrics and mean response time (MRT, in ms) for first-stage methods, on MSMARCO Dev Queries, TREC 2019 queries, and TREC 2020 queries. The symbol ∇ denotes a significant difference viz. DeepImpact

Strategy	NDCG@10	MRR@10	MAP	MRT
MSMARCO Dev Queries				
BM25	0.235 [∇]	0.188 [∇]	0.196 [∇]	13.24
DeepCT	0.298 [∇]	0.244 [∇]	0.252 [∇]	10.91
DocT5Query	0.338 [∇]	0.278 [∇]	0.286 [∇]	12.62
DeepImpact	0.385	0.326	0.332	58.64
TREC 2019				
BM25	0.497 [∇]	0.683	0.290 [∇]	10.27
DeepCT	0.578 [∇]	0.714	0.329 [∇]	11.02
DocT5Query	0.648	0.799	0.405	11.76
DeepImpact	0.695	0.863	0.456	51.23
TREC 2020				
BM25	0.483 [∇]	0.659 [∇]	0.286 [∇]	14.67
DeepCT	0.550 [∇]	0.705	0.349 [∇]	12.00
DocT5Query	0.619	0.742	0.408	15.51
DeepImpact	0.651	0.820	0.426	58.00

Table 3: Effectiveness metrics and mean response time (MRT, in ms) using several re-ranking techniques on MSMARCO Dev Queries, TREC 2019 queries, and TREC 2020 queries. ∇ denotes a significant difference viz. ColBERT E2E

Strategy	NDCG@10	MRR@10	MRT
MSMARCO Dev Queries			
DeepImpact + EPIC	0.367 [∇]	0.303 [∇]	194.64
DeepImpact + ColBERT	0.425	0.362	81.00
ColBERT E2E	0.424	0.361	380.97
TREC 2019			
DeepImpact + EPIC	0.711	0.880	191.23
DeepImpact + ColBERT	0.722	0.826	73.29
ColBERT E2E	0.694	0.826	370.98
TREC 2020			
DeepImpact + EPIC	0.646	0.773	196.00
DeepImpact + ColBERT	0.691	0.781	79.84
ColBERT E2E	0.676	0.776	364.82

📖 Mallia, A. et al. 2021. Learning Passage Impacts for Inverted Indexes.

🔧 Et si on faisait expansion **et** pondération en un seul modèle ?

MODÈLES PARCIMONIEUX ► VERS SPLADE : DE SPARTA À SPARterm

🔧 Idée = prédire directement des poids sur le **vocabulaire entier** (expansion + pondération en un seul modèle)

Sparta (2020)

Premier modèle à prédire des poids parcimonieux sur tout le vocabulaire via des représentations contextualisées

📖 Zhao, T. et al. 2020. SPARTA: Efficient Open-Domain Question Answering via Sparse Transformer Matching Retrieval.

SparTerm (2020)

Améliore Sparta : utilise la tête **MLM** de BERT pour projeter sur le vocabulaire, puis pooling (max ou sum) pour obtenir 1 poids par terme

📖 Bai, Y. et al. 2020. SparTerm: Learning Term-based Sparse Representation for Fast Text Retrieval.

SPLADE (2021)

Raffine SparTerm avec une meilleure agrégation (log-saturation) et une régularisation FLOPS

🔧 La tâche de MLM induit naturellement une forme d'expansion du vocabulaire

>> distilbert-base-uncased [Sanh et al. 2019]	
<i>prostate</i>	→ (<i>prostate</i> , <i>.</i> , <i>the</i>)
<i>cancer</i>	→ (<i>cancer</i> , <i>tumor</i> , <i>##mour</i>)
<i>detection</i>	→ (<i>detection</i> , <i>identification</i> , <i>screening</i>)
<i>treatment</i>	→ (<i>.</i> , <i>;</i> , <i>treatment</i>)
>> google/electra-base-generator [Clark et al. 2020]	
<i>prostate</i>	→ (<i>prostate</i> , <i>##iate</i> , <i>mal</i>)
<i>cancer</i>	→ (<i>cancer</i> , <i>cancers</i> , <i>tumor</i>)
<i>detection</i>	→ (<i>detection</i> , <i>detecting</i> , <i>screening</i>)
<i>treatment</i>	→ (<i>treatment</i> , <i>therapy</i> , <i>treatments</i>)
>> naver/splade-cocondenser-ensembledistil [Formal et al. 2021c]	
<i>prostate</i>	→ (<i>prostate</i> , <i>bp</i> , <i>ur</i>)
<i>cancer</i>	→ (<i>cancer</i> , <i>tumor</i> , <i>disease</i>)
<i>detection</i>	→ (<i>detection</i> , <i>detect</i> , <i>test</i>)
<i>treatment</i>	→ (<i>treatment</i> , <i>therapy</i> , <i>treated</i>)

Table 3.1: MLM prediction for the Robust04 query “*prostate cancer detection treatment*”. For each token, we show the top-3 predicted tokens, i.e., with the highest MLM logits. Note that these models use the WordPiece vocabulary (Section 2.4.2). Also, note that only the generator part of ELECTRA has been pre-trained with MLM. We also include for comparison the prediction for one of our SPLADE model.

MODÈLES PARCIMONIEUX ► SPLADE (DÉTAILS)

📖 Formal, T. et al. 2021. SPLADE: Sparse Lexical and Expansion Model for First Stage Ranking. *Proceedings of the 44th International ACM SIGIR Conference on Research and Development in Information Retrieval*.

On estime le poids w_{td} d'un terme t dans un document d avec

$$w_{td} = \log \left(1 + \max_{i \in d} \text{ReLU}(y_i^{(t)}) \right)$$

avec

$$y_i^{(t)} = \text{BERT}_i(d) \cdot \theta_t + b_t$$

où $\text{BERT}_i(d)$ est l'embedding contextualisé (BERT) du i ème token du document d

OBJECTIF D'ENTRAÎNEMENT

- **Coût de RI** : infoNCE ou distillation
- **Régularisation FLOPS** : limiter le nombre de termes actifs

$$\mathcal{L}_{\text{FLOPS}} = \lambda_d \sum_{t \in V} \bar{w}_{t,d}^2 + \lambda_q \sum_{t \in V} \bar{w}_{t,q}^2$$

où $\bar{w}_{t,q}$ et $\bar{w}_{t,d}$ sont les poids moyens du terme t sur les requêtes / documents (batch)

MODÈLES PARCIMONIEUX ► CONCLUSION

- ✚ On arrive à de très bons résultats (bien meilleurs que BM25)
- ✚ Modèles faciles à apprendre (SparTerm, SPLADE) ou à utiliser (DocTTTTT)
- ✖ Pour arriver à l'état de l'art, il faut quand même ré-ordonner (e.g. avec monoBERT)

MODÈLES D'INTERACTION




Principe

Construire une matrice M de similarités terme-à-terme entre la requête q et le document d

$$M_{ij} = \phi(q_i, d_j)$$


où ϕ mesure la similarité (cosinus, dot product, exact match, ...)

Intérêt : capturer les correspondances lexicales (exact match) **et** sémantiques (soft match)
Utilisation de techniques d'agrégation 2D (convolution et/ou pooling) pour extraire un score



MODÈLES D'INTERACTION ► COLBERT

- 🔑 Modèle d'interaction basé sur une aggrégation (maximum)
- 🔑 Permet de construire un index !



$$score(q, d) = \sum_{i=1}^{|q|} \max_{j=1}^{|d|} \text{sim}(q_i, d_j)$$

MODÈLES D'INTERACTION ► COLBERT : AVANTAGES ET INCONVÉNIENTS

AVANTAGES

-  Meilleure efficacité que les bi-encodeurs
Appariement fin au niveau des tokens
-  Permet de construire un index ANN
Pré-calcul des embeddings de tokens hors-ligne
-  Plus rapide que les cross-encodeurs
Pas d'attention requête-document à l'exécution

INCONVÉNIENTS

-  Stockage : tous les embeddings de tokens
 $\sim 128 \text{ dims} \times \sim 180 \text{ tokens} \times 4 \text{ octets} \approx 90 \text{ Ko/doc}$
MS MARCO (8.8M docs) $\approx 800 \text{ Go}$
-  Vitesse : recherche ANN par token de requête
 $|q|$ recherches ANN au lieu d'une seule

🔧 Technique de compression

$$\hat{x}_{di} = \underbrace{z_{j(x_{di})}}_{\text{cluster}} + \underbrace{\tilde{x}_{di}}_{\text{résidu}}$$

📖 Santhanam, K. et al. 2021. ColBERTv2: Effective and Efficient Retrieval via Lightweight Late Interaction.

🔧 PLAID = 3 filtrages de plus en plus précis, puis calcul complet (avec résidus)

System	MRR@10	R@100	R@1k	Latency (ms)		
				1-CPU	8-CPU	GPU
BM25 (PISA [34]; k = 1000)	18.7*	-	-	8.3*	-	-
SPLADEv2 (PISA; k = 1000)	36.8*	-	97.9*	220.3*	-	-
ColBERTv1	36.1	87.3	95.2	-	-	54.3
Vanilla ColBERTv2 (p=2, c=2 ¹³)	39.7	90.4	96.6	3485.1	921.8	53.4
Vanilla ColBERTv2 (p=4, c=2 ¹⁶)	39.7	91.4	98.3	-	4568.5	259.6
PLAID ColBERTv2 (k = 10)	39.4	-	-	185.5	31.5	11.5
PLAID ColBERTv2 (k = 100)	39.8	90.6	-	222.3	52.9	20.2
PLAID ColBERTv2 (k = 1000)	39.8	91.3	97.5	352.3	101.3	38.4

Table 3: End-to-end in-domain evaluation on the MS MARCO v1 benchmark. Numbers marked with an asterisk are copied from Formal et al. [11] for SPLADEv2 quality and Mackenzie et al. [30] for latencies.


System	Success@5	Success@100	Latency (ms)	
			CPU (8)	GPU
BM25	47.8*	77.6*	-	-
SPLADEv2	67.0*	89.0*	-	-
Vanilla ColBERTv2 (p=2, c=2 ¹³)	69.3	90.3	1508.4	66.9
PLAID ColBERTv2 (k = 10)	69.1	-	35.5	9.2
PLAID ColBERTv2 (k = 100)	69.4	89.9	64.8	17.4
PLAID ColBERTv2 (k = 1000)	69.6	90.5	163.1	27.3

Table 5: End-to-end out-of-domain evaluation on the (dev) pooled dataset of the LoTTE benchmark. Numbers marked with an asterisk were taken from Santhanam et al. [42].

📖 Santhanam, K. et al. 2022. PLAID: An Efficient Engine for Late Interaction Retrieval. Technical Report #arXiv:2205.09707.

🔑 On utilise BERT en concaténant question et document cible

$$rsv(q, d) = x^{[CLS]}([CLS] \text{ q } [SEP] \text{ d})$$




📖 Nogueira, R. and Cho, K. 2019. Passage Re-ranking with BERT.

		TREC 2019 DL Passage		
Method		nDCG@10	MAP	Recall@1k
(3a)	BM25 (Anserini, $k = 1000$)	0.5058	0.3773	0.7389
(3b)	+ monoBERT _{Large}	0.7383	0.5058	0.7389
(4a)	BM25 + RM3 (Anserini, $k = 1000$)	0.5180	0.4270	0.7882
(4b)	+ monoBERT _{Large}	0.7421	0.5291	0.7882

✚ De très bon résultats...

✖ Mais très gourmand : des travaux récents permettent de réduire le temps de traitement substantiellement

MODÈLES D'INTERACTION ► CROSS-ENCODER - LATE INTERACTION (PRETTR)



MODÈLES D'INTERACTION ► CROSS-ENCODER - LATE INTERACTION (PRETTR) (2)

TREC WebTrack 2012										
Compression	P@20					ERR@20				
	<i>l</i> = 7	<i>l</i> = 8	<i>l</i> = 9	<i>l</i> = 10	<i>l</i> = 11	<i>l</i> = 7	<i>l</i> = 8	<i>l</i> = 9	<i>l</i> = 10	* <i>l</i> = 11
(none)	0.3180	0.3140	0.3130	0.3360	0.3380	0.2255	0.2344	0.2297	0.2295	0.1940
<i>e</i> = 384 (50%)	0.3430	0.3260	0.2980	0.3360	0.3090	0.2086	0.2338	0.1685	0.2233	0.2231
<i>e</i> = 256 (67%)	0.3380	0.3120	↑ 0.3440	0.3260	0.3250	↑ 0.2716	0.2034	↑ 0.2918	0.1909	0.2189
<i>e</i> = 128 (83%)	0.3100	0.3210	0.3320	0.3220	0.3370	0.2114	0.2234	0.2519	0.2239	0.2130

Ranker	TREC WebTrack 2012					Robust04
	Total	Speedup	Query	Decom.	Combine	Total
Base	1.941s	(1.0×)	-	-	-	2.437s
<i>l</i> = 1	1.768s	(1.1×)	2ms	10ms	1.756s	2.222s
<i>l</i> = 2	1.598s	(1.2×)	3ms	10ms	1.585s	2.008s
<i>l</i> = 3	1.423s	(1.4×)	5ms	10ms	1.409s	1.792s
<i>l</i> = 4	1.253s	(1.5×)	6ms	10ms	1.238s	1.575s
<i>l</i> = 5	1.080s	(1.8×)	7ms	10ms	1.063s	1.356s
<i>l</i> = 6	0.906s	(2.1×)	9ms	10ms	0.887s	1.138s
<i>l</i> = 7	0.735s	(2.6×)	10ms	10ms	0.715s	0.922s
<i>l</i> = 8	0.562s	(3.5×)	11ms	10ms	0.541s	0.704s
<i>l</i> = 9	0.391s	(5.0×)	12ms	10ms	0.368s	0.479s
<i>l</i> = 10	0.218s	(8.9×)	14ms	10ms	0.194s	0.266s
<i>l</i> = 11	0.046s	(42.2×)	15ms	10ms	0.021s	0.053s

Performance et temps de la latence sur la collection TREC WebTrack 2012 (ré-ordonnancement de 100 documents)

MacAvaney, S. et al. 2020. Efficient Document Re-Ranking for Transformers by Precomputing Term Representations. Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval.

MODÈLES D'INTERACTION ► CONCLUSION

 Les modèles d'interaction sont les plus performants

 C'est lourd - même si les travaux montrent qu'on peut beaucoup simplifier les modèles tout en gardant de bons résultats

 (en général, sauf ColBERT) Mécanisme en deux temps : on sélectionne e.g. 1000 documents qu'on ré-ordonne

APPROCHES GÉNÉRATIVES

🔧 Les LLMs ouvrent de nouvelles approches pour la RI

Ré-ordonnement par LLM

Utiliser un LLM pour ré-ordonner les résultats d'un premier système

Recherche générative (Generative Retrieval)

Le modèle génère directement les identifiants des documents

Génération de données synthétiques

Utiliser un LLM pour générer des données d'entraînement

RAG (Retrieval-Augmented Generation)

Combiner recherche et génération pour répondre aux questions

APPROCHES GÉNÉRATIVES ► RÉ-ORDONNANCEMENT PAR LLM

📖 Sun, W. et al. 2023. *Is ChatGPT Good at Search? Investigating Large Language Models as Re-Ranking Agents*. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, EMNLP 2023, Singapore, December 6-10, 2023*.

💡 Idée : utiliser un LLM pour ré-ordonner une liste de documents candidats

APPROCHES PRINCIPALES

Pointwise

Le LLM estime la pertinence de chaque document indépendamment (ex. "Is this document relevant to the query?")

Pairwise

Le LLM compare deux documents à la fois

Listwise (RankGPT)

Le LLM reçoit toute la liste et produit une permutation

💡 **Avantage**

Zero-shot : pas besoin de données d'entraînement spécifiques à la tâche

APPROCHES GÉNÉRATIVES ► RANKGPT : RÉ-ORDONNANCEMENT LISTWISE

📖 Sun, W. et al. 2023. *Is ChatGPT Good at Search? Investigating Large Language Models as Re-Ranking Agents*. *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing, EMNLP 2023, Singapore, December 6-10, 2023*.

🔧 Le LLM reçoit la requête et N passages, et retourne une permutation

🔧 Technique de fenêtre glissante pour traiter plus de documents que la taille du contexte

PROMPT (SIMPLIFIÉ)



I will provide you with passages, each indicated by a numerical identifier [].
Rank the passages based on their relevance to the search query:

RÉSULTATS

🟢 Performances comparables ou supérieures aux modèles supervisés (monoBERT)

🔴 Coût d'inférence élevé (appels LLM)

🔧 Distillation possible vers des modèles plus petits

📖 Zero-Shot Listwise Document Reranking with a Large Language Model: 2023. <http://arxiv.org/abs/2305.02156>.

APPROCHES GÉNÉRATIVES ► RECHERCHE GÉNÉRATIVE (DSI)

📖 Tay, Y. et al. 2022. *Transformer Memory as a Differentiable Search Index*.

🔑 Idée : le modèle mémorise le corpus et génère directement les identifiants des documents

DEUX PHASES

1. **Indexation** : le modèle apprend l'association document → identifiant (docid)
2. **Recherche** : étant donné une requête, le modèle génère autoregressivement le docid

REPRÉSENTATION DES IDENTIFIANTS

- Identifiants atomiques (un token par document)
 - Identifiants structurés (hiérarchiques, clustering sémantique)
 - Chaînes de caractères (titre, URL, ...)
- ✅ Pas besoin d'index externe
- ❌ Passage à l'échelle difficile (le modèle doit mémoriser tout le corpus)

APPROCHES GÉNÉRATIVES ► GENRE : AUTOREGRESSIVE ENTITY RETRIEVAL

📖 *Cao, N.D. et al. 2020. Autoregressive Entity Retrieval.*

- 🔧 Génération contrainte du nom de l'entité (ou du titre du document)
- 🔧 Utilisation d'un préfixe trie pour restreindre la génération aux entités valides

AVANTAGES

- ➕ Pas besoin de représentation vectorielle des entités
- ➕ Généralisation naturelle à de nouvelles entités (si ajoutées au trie)
- ➖ Limité aux cas où l'identifiant est une chaîne de caractères significative

APPROCHES GÉNÉRATIVES ► GÉNÉRATION DE DONNÉES SYNTHÉTIQUES

🔑 Utiliser des LLMs pour générer des données d'entraînement pour la RI

INPARS

📖 Bonifacio, L. et al. 2022. *InPars: Unsupervised Dataset Generation for Information Retrieval*. *Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval*.

🔑 Générer des requêtes synthétiques à partir de documents avec un LLM (few-shot)

🔑 Filtrer les paires générées avec un modèle de ré-ordonnancement

🔑 Entraîner un modèle de RI sur les données synthétiques

INTÉRÊT

➕ Adaptation à un nouveau domaine sans données annotées

➕ Peu coûteux (quelques exemples suffisent pour le few-shot)

🔑 Évolution de Doc2Query avec des modèles plus puissants

🔑 Les LLMs transforment profondément la RI

TENDANCES ACTUELLES

- Le ré-ordonnancement par LLM est très efficace mais coûteux
- La recherche générative reste un défi à l'échelle
- La génération de données synthétiques démocratise l'adaptation de domaine
- RAG est devenu le paradigme dominant pour les applications LLM

🔑 Pour aller plus loin :

📖 Li, X. et al. 2024. *From Matching to Generation: A Survey on Generative Information Retrieval*.

CONCLUSION

CONCLUSION ► JEUX DE DONNÉES ET BENCHMARKS

MS MARCO

Le plus utilisé pour le Deep Learning en RI (TREC Deep Learning Track)

- Questions en langage naturel, passages web
- Tâches : ordonnancement de documents et de passages

📖 Nguyen, T. et al. 2016. *MS MARCO: A Human Generated MACHine Reading COMprehension Dataset*.

BEIR

Benchmark d'évaluation zero-shot sur 18 jeux de données hétérogènes

- Évalue la capacité de généralisation des modèles

📖 Thakur, N. et al. 2021. *BEIR: A Heterogenous Benchmark for Zero-shot Evaluation of Information Retrieval Models*.

MTEB

Benchmark massif pour les modèles d'embedding de texte

- Évalue sur de nombreuses tâches (retrieval, classification, clustering, ...)

📖 MTEB: Massive Text Embedding Benchmark: 2023. <http://arxiv.org/abs/2210.07316>.

CONCLUSION ► RÉSUMÉ

🔑 Domaine très dynamique, porté par les transformers et les LLMs

ÉTAT DE L'ART = APPROCHES EN (DEUX) TEMPS

1. Filtrage

1. BM25 (ou autre)...
2. Méthodes neuronales denses + FAISS (E5, GTE, BGE, ...)
3. Méthodes neuronales parcimonieuses : SPLADE, DocT5, ...

2. Ré-ordonnancement = Cross-encoder (monoBERT) ou LLM (RankGPT)

Autre option = approche multi-stage comme PLAID-ColBERT

⚠ Documents longs : approche standard = on découpe puis maximum

APPRENTISSAGE

🔑 Beaucoup de coûts possibles (mais la loss contrastive marche bien en général)

🔑 Distillation / pré-entraînement

🔑 Choix des négatifs (hard negative mining) est crucial

CONCLUSION ► RÉFÉRENCES

🔑 Learning to Rank for Information Retrieval (livre de référence)

📖 Liu, T.-Y. 2011. *Learning to Rank for Information Retrieval*.

🔑 Efficient and Effective Tree-based and Neural Learning to Rank (survey 2023)

📖 Bruch, S. et al. 2023. *Efficient and Effective Tree-based and Neural Learning to Rank*.

🔑 Lecture Notes on Neural Information Retrieval

📖 Lecture Notes on Neural Information Retrieval: 2022. <http://arxiv.org/abs/2207.13443>.

🔑 Sur la RI et les transformers (très complet... en 2020)

📖 Lin, J. et al. 2020. *Pretrained Transformers for Text Ranking: BERT and Beyond*.

🔑 LLMs pour la RI (survey 2023)

📖 Large Language Models for Information Retrieval: A Survey: 2023. <http://arxiv.org/abs/2308.07107>.

🔑 Sur la RI générative (survey 2024)

📖 Li, X. et al. 2024. *From Matching to Generation: A Survey on Generative Information Retrieval*.